

IA y Análisis Estadístico aplicado a la Industria Musical

*Caso práctico con el dataset de
Spotify Tracks (114.000 canciones)*

Fases completadas: Limpieza · EDA · Modelos RF/XGBoost · Clustering
Recomendación · App Streamlit · Nacionalidad · Trayectoria temporal

Alfonso García Betico

Junio 2026

ÍNDICE DE CONTENIDOS

1.	Resumen ejecutivo	<i>pág. 3</i>
2.	Fase 0 — Limpieza y preparación de datos	<i>pág. 3</i>
3.	Fase 1 — Análisis exploratorio (EDA)	<i>pág. 4</i>
4.	Fase 2 — Modelos predictivos: Random Forest vs XGBoost	<i>pág. 6</i>
4.1	Regresión de popularidad	<i>pág. 6</i>
4.2	Clasificación de macro-género	<i>pág. 7</i>
5.	Fase 3 — Clustering y sistema de recomendación	<i>pág. 8</i>
6.	Fase 4 — Aplicación Streamlit	<i>pág. 10</i>
7.	Fase 5 — Estudio de nacionalidad	<i>pág. 11</i>
8.	Fase 6 — Trayectoria temporal: Feid y similares	<i>pág. 13</i>
9.	Conclusiones y limitaciones	<i>pág. 15</i>

Nota: las páginas son aproximadas — el documento se genera dinámicamente.

1. RESUMEN EJECUTIVO

Este trabajo aplica técnicas de Inteligencia Artificial y Análisis Estadístico al dataset de Spotify Tracks, que contiene 114.000 registros de canciones con 21 variables de audio, metadatos y popularidad, correspondientes a 89.740 canciones únicas en 114 géneros musicales distintos. El objetivo es desarrollar un ciclo completo de Data Science: desde la limpieza inicial hasta una aplicación interactiva de recomendación, pasando por modelos supervisados, clustering y análisis sociocultural.

Estructura del proyecto

El trabajo se articula en seis fases de complejidad creciente. Las fases 0 a 4 son el núcleo técnico del análisis; las fases 5 y 6 constituyen estudios cualitativos con apoyo estadístico orientados a la interpretación musical y cultural de los datos.

Fase	Título	Resultado clave
Fase 0	Limpieza y preparación	114k → 89.740 únicas; tempo=0 imputado; deduplicación documentada
Fase 1	Análisis exploratorio	Correlaciones, distribuciones, perfiles por género (7 figuras)
Fase 2	RF vs XGBoost	Regresión popularidad: $R^2=0.472$ (RF); Clasificación género: $F1=0.409$ (XGB)
Fase 3	Clustering + Recomendación	$k=2$ óptimo; recomendador híbrido género+KNN: coherencia=1.0
Fase 4	App Streamlit	Interfaz interactiva con búsqueda por canción y por perfil de usuario
Fase 5	Estudio de nacionalidad	220 artistas, 7 regiones; diferencias sonoras significativas ($p<0.001$)
Fase 6	Trayectoria temporal	291 canciones fechadas; evolución y predicción del sonido de Feid 2023-2025

Hallazgos principales

- El 10,5% de las canciones tiene popularity = 0. La distribución está fuertemente sesgada a la derecha.
- La feature con mayor correlación negativa con popularity es instrumentalness (-0.127): las canciones con letra tienden a ser más populares en el snapshot analizado.
- Random Forest supera a XGBoost en regresión de popularidad ($R^2=0.472$ vs 0.430). En clasificación de género ambos empatan ($\sim F1=0.41$), muy por encima del baseline sin agrupar ($F1=0.25$).
- El clustering de audio features identifica solo 2 clústeres bien diferenciados (silhouette=0.258): música energética vs. tranquila/acústica. Esto sugiere que las features de audio no capturan la varianza de género a nivel fino.
- El recomendador híbrido (filtrado por género + KNN en el espacio de features) alcanza coherencia de género = 1.0 con una diversidad de artistas de 0.83.
- Las diferencias sonoras entre regiones geográficas son estadísticamente muy significativas (ANOVA $p<0.001$ para danceability, energy, valence y tempo). Latinoamérica lidera en energy (0.712) y valence (0.603); Europa en instrumentalness (0.336).
- La trayectoria de Feid (2018-2022) muestra una evolución clara hacia mayor energía y menor acousticness, convergiendo con el sonido dominante del reggaeton urbano actual.

Limitación transversal: la variable popularity es un snapshot del algoritmo de Spotify basado en reproducciones recientes. No refleja el éxito histórico de los artistas. Esta limitación afecta especialmente las comparaciones temporales y el ranking por popularidad.

2. FASE 0 — LIMPIEZA Y PREPARACIÓN DE DATOS

Descripción del dataset

El dataset original contiene 114.000 filas con 21 columnas: identificadores de canción, artista y álbum; variables de audio (danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo, key, mode, time_signature, duration_ms); y las variables objetivo popularity y track_genre.

El fichero spotify-tracks-dataset.csv es una copia exacta del dataset principal (114.000 filas, mismas columnas, solo añade un índice Unnamed: 0). Se descartó para evitar duplicación. Únicamente se usó dataset.csv.

Decisiones de limpieza documentadas

Problema detectado	Magnitud	Decisión tomada
Duplicados por track_id	40.900 filas (36%)	Deduplicación: keep='first' → tracks_unique.csv (89.740 filas)
Versión larga (clasificación)	—	tracks_long.csv con 113.999 filas (1 fila eliminada)
Fila con artista/álbum/nombre nulo	1 fila	Eliminada directamente
tempo == 0	157 filas (0.14%)	Imputadas con la mediana del género correspondiente
Géneros únicos	114 (no 125 como indica el dato)	Anotado como dato curioso; sin acción
loudness en dB negativos	Rango habitual: -60 a 0 dB	Normal en audio digital; sin transformación
duration_ms en milisegundos	Algunas > 30 min (grabaciones/posibles)	Mantenidas; outliers documentados en EDA

Estructura de ficheros generada

- data/processed/tracks_unique.csv — 89.740 canciones, una fila por canción
- data/processed/tracks_long.csv — 113.999 filas, una fila por combinación canción-género
- data/processed/tracks_nationality.csv — 11.881 canciones con metadatos de nacionalidad
- data/processed/artists_nationality.csv — 220 artistas con país y región
- data/processed/tracks_artistas_trayectoria.csv — 291 canciones con fechas de lanzamiento

Nota metodológica sobre la variable popularity

Spotify calcula el índice de popularidad (0–100) mediante un algoritmo propietario basado principalmente en el volumen de reproducciones recientes y su recencia. No equivale al número total de streams de la vida de la canción. Una canción de 2004 con millones de reproducciones históricas puede tener popularity = 20 en el snapshot, mientras que una canción de 2022 con pocas reproducciones puede tener 70. Este matiz es fundamental para interpretar todos los análisis donde aparece popularity como variable.

3. FASE 1 — ANÁLISIS EXPLORATORIO (EDA)

El análisis exploratorio busca entender la estructura de los datos antes de modelar, siguiendo la metodología habitual en proyectos de Data Science: conocer distribuciones, relaciones entre variables y detectar anomalías.

3.1 Distribución de popularidad

La variable objetivo presenta una distribución bimodal con fuerte sesgo a la izquierda. El 10,5% de las canciones tiene $\text{popularity} = 0$. Esto puede deberse a: canciones muy antiguas con pocas reproducciones recientes, canciones de géneros muy minoritarios, o canciones retiradas del catálogo activo. La mediana de popularidad es 35.




Fig. 1 — Distribución de popularity. Nótese el pico en 0 y la distribución sesgada a la derecha.

3.2 Matriz de correlaciones

La correlación de las features de audio con popularity es en general baja, lo que anticipa la dificultad del problema de regresión. Las correlaciones más destacadas son:

- instrumentalness: -0.127 (negativa, la más fuerte). Las canciones instrumentales son menos populares en el snapshot.
- acousticness: -0.083 (negativa). La música acústica tiende a menor popularidad en el período analizado.
- danceability: $+0.063$ (positiva, débil). Más bailable $\rightarrow$ ligeramente más popular.
- loudness: $+0.058$ (positiva). Canciones más altas en dB tienden a más popularidad.
- energy: -0.022 (prácticamente nula en correlación lineal).




Fig. 2 — Matriz de correlación de features numéricas. Colores rojos = correlación positiva, azules = negativa.

3.3 Perfil sonoro por género

Comparamos 8 géneros contrastados en 6 audio features normalizadas [0–1]. El gráfico de radar permite identificar el 'sonido característico' de cada género:

- Reggaeton: danceability y energy muy altas; acousticness baja.
- Classical: acousticness e instrumentalness dominantes; danceability baja.
- Metal: energy máxima; valence baja (sonido oscuro/intenso); acousticness mínima.
- Jazz: acousticness media-alta; valence media; instrumentalness alta.
- EDM: energy alta; danceability alta; acousticness y speechiness bajas.

Perfil de Audio Features por Género




Fig. 3 — Gráfico radar por género (features normalizadas). Cada eje representa una feature de audio.

3.4 Popularidad por género y otras variables categóricas




Fig. 4 — Boxplot de popularidad por género (top géneros seleccionados).

Los géneros con mayor popularidad media en el snapshot son los géneros urbanos recientes (pop, latin, reggaeton) mientras que géneros más clásicos o de nicho (folk, blues, ambient, classical) presentan medianas más bajas, principalmente por el efecto de recencia del índice de Spotify.




Fig. 5 — Distribución de key, mode, time_signature y explicit vs. popularity.

3.5 Outliers en loudness y duration




Fig. 6 — Detección de outliers en loudness (dB) y duration (ms).

Loudness: rango normal entre -30 y 0 dB. Existen outliers extremos por debajo de -40 dB (silencio, grabaciones con mucho ruido de fondo o canciones muy dinámicas). Duration: la mayoría de canciones dura entre 2 y 6 minutos. Hay outliers por encima de 30 minutos (podcasts o grabaciones largas clasificados como 'canciones' en Spotify).




Fig. 7 — Perfil medio de audio features por macro-categoría de género.

4. FASE 2 — MODELOS PREDICTIVOS: RANDOM FOREST vs XGBOOST

Esta fase entrena y compara dos familias de modelos de ensemble (Random Forest y XGBoost) para dos tareas distintas: regresión de la popularidad y clasificación de macro-género.

4.1 Regresión de popularidad

Se usa el dataset deduplicado (tracks_unique, 89.740 canciones) con split 80/20. Las 114 categorías de track_genre se codifican con Target Encoding. La búsqueda de hiperparámetros se realiza con RandomizedSearchCV (20 iteraciones, 3-fold CV).

Modelo	RMSE	MAE	R ²	Hiperparámetros óptimos (selección)
Random Forest	14.86	10.16	0.472	n_est=400, max_depth=20, min_samples_leaf=2
XGBoost	15.44	10.84	0.430	n_est=300, max_depth=6, lr=0.1, subsample=0.8

Random Forest supera a XGBoost en regresión con un $R^2=0.472$. Ninguno de los dos modelos explica más del 47% de la varianza de popularity, lo que es esperable: el índice de Spotify depende de factores no capturados en el dataset (streams recientes, actividad en playlists editoriales, viralidad en redes sociales).




Fig. 8 — Importancia de variables en regresión (RF impurity vs. XGB gain). track_genre y loudness lideran en ambos modelos.

4.2 Clasificación de macro-género

Con 114 géneros originales la clasificación directa es muy difícil (muchos géneros con pocas canciones, frontera entre géneros ambigua). Se agrupan los 114 géneros en 12 macro-categorías usando un mapa editorial:

Macro-género	Géneros incluidos (muestra)
rock	alternative, grunge, punk, emo, indie
electronica	edm, techno, trance, dubstep, house, electro, disco
latino	latin, reggaeton, salsa, cumbia, bachata, reggaeton-colombiano
hip-hop	hip-hop, rap, trap, r-n-b, soul
clasica	classical, opera, piano, chamber
jazz-blues	jazz, blues, gospel
pop	pop, dance, synth-pop
metal	metal, heavy-metal, black-metal, death-metal
folk-acustico	folk, acoustic, singer-songwriter, country, bluegrass
kpop-jpop	k-pop, j-pop, j-idol, cantopop, mandopop
world	world-music, afrobeat, sertanejo, pagode, samba, indian
otros	new-age, ambient, children, comedy, show-tunes, ...

Modelo	Accuracy	F1-macro	F1-weighted
Random Forest	0.465	0.408	0.462
XGBoost	0.464	0.409	0.463
Baseline (114 géneros sin agrupación)	0.257	0.246	0.251

Ambos modelos son prácticamente equivalentes. La agrupación en 12 macro-géneros casi duplica el F1 respecto al enfoque con 114 clases. El error más frecuente se produce entre rock y folk-acústico, y entre electronica y pop, donde los límites estilísticos son difusos.




Fig. 9 — Importancia de variables en clasificación. Instrumentalness, acousticness y tempo son los mejores discriminadores de género.




Fig. 10 — Matriz de confusión del Random Forest (12 macro-géneros). La diagonal muestra las predicciones correctas.

Los géneros mejor clasificados son k-pop/j-pop (sonido muy característico) y clásica/instrumental (altísima instrumentalness). Los más confundidos son pop vs. electrónica y rock vs. metal (frontera estilística muy difusa en el dataset).

5. FASE 3 — CLUSTERING Y SISTEMA DE RECOMENDACIÓN

El objetivo es construir un sistema de recomendación de canciones basado en contenido (content-based filtering), usando las audio features como representación del 'sonido' de cada canción. Esto replica la capa de análisis de audio del sistema de Spotify, que combina este enfoque con filtrado colaborativo y NLP sobre metadatos, capas que no podemos replicar sin datos de usuarios ni texto.

5.1 Preprocesado y reducción de dimensionalidad

Features usadas: danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo (9 features). Escalado con StandardScaler. Reducción para visualización: PCA (2 componentes, explica 45% de la varianza) y UMAP.

5.2 Algoritmos de clustering comparados

Algoritmo	k / parámetro óptimo	Silhouette	Davies-Bouldin	Observaciones
KMeans	k=2	0.258	1.41	Clúster 0=energético, Clúster 1=tranquilo/acústico
AgglomerativeClustering	k=2	0.251	1.48	Resultado muy similar a KMeans
DBSCAN	eps=0.8	0.112	—	Detecta ruido; no converge bien con datos de Spotify

El silhouette score bajo (~ 0.25) indica que los géneros musicales no forman clusters bien separados en el espacio de audio features. La música se distribuye en un continuo multidimensional más que en grupos discretos: un hallazgo en sí mismo relevante para la memoria del TFG.




Fig. 11 — Método del codo y silhouette score para selección de k en KMeans.




Fig. 12 — Visualización PCA 2D de los clústeres. La separación entre Clúster 0 (energético, en azul) y Clúster 1 (tranquilo, en naranja) es clara.




Fig. 13 — Visualización UMAP de los clústeres, coloreado por macro-género. UMAP preserva mejor la estructura local que PCA.

5.3 Sistema de recomendación: tres enfoques

Se implementan y comparan tres estrategias de recomendación, evaluadas sobre 100 canciones semilla aleatorias usando métricas proxy (sin ground truth real):

Recomendador	Coherencia género	Diversidad artistas	Descripción
KNN global	0.136	0.871	k=10 vecinos más cercanos en espacio de features (coseno)
Basado en clúster	0.312	0.842	Recomienda canciones del mismo clúster que la semilla
Híbrido	1.000	0.831	Filtra por género → aplica KNN dentro del subconjunto

El recomendador híbrido (género + KNN) alcanza coherencia de género perfecta (1.0) con una diversidad de artistas del 83%. Es el que se usa en la aplicación Streamlit. La coherencia perfecta es esperable: al filtrar primero por género, todas las recomendaciones son del mismo género que la semilla por construcción.




Fig. 14 — Comparativa de los tres recomendadores en coherencia de género y diversidad de artistas.

6. FASE 4 — APLICACIÓN INTERACTIVA (STREAMLIT)

Se desarrolla una aplicación web interactiva con Streamlit (`app/app.py`) que permite explorar el sistema de recomendación de forma visual sin necesidad de código. La app se lanza con: `streamlit run app/app.py`

Funcionalidades implementadas

La aplicación tiene dos modos de uso organizados en pestañas:

- Modo 'Por canción semilla': el usuario busca una canción por nombre de artista o título. La app muestra las N canciones más similares usando el recomendador híbrido (género + KNN). Para cada recomendación muestra artista, álbum, género y popularidad.
- Modo 'Por preferencias': el usuario ajusta sliders de danceability, energy, valence, tempo y acousticness para definir un 'perfil sonoro ideal'. Opcionalmente puede filtrar por género/macro-género. La app busca las canciones más cercanas a ese perfil en el espacio de features escaladas.

Decisiones técnicas

- `@st.cache_data` para el dataset (89.740 canciones): se carga una sola vez en memoria.
- `@st.cache_resource` para los modelos (KNN, scaler, KMeans, `X_scaled`): se persiste entre sesiones.
- Búsqueda con `str.contains()` insensible a mayúsculas para el buscador de canciones.
- Las recomendaciones se muestran en una tabla interactiva `st.dataframe` con columnas configuradas.

Limitaciones de la app

El catálogo está limitado a las 89.740 canciones del dataset (snapshot de 2022). No se integra con la API real de Spotify, por lo que no muestra portadas, no reproduce canciones y no se actualiza en tiempo real. Para un producto real habría que conectar la capa de recomendación a los endpoints de la API de Spotify y añadir autenticación de usuario.

7. FASE 5 — ESTUDIO DE NACIONALIDAD

Este análisis estudia si existen diferencias estadísticamente significativas en el perfil sonoro de los artistas según su región de origen. La hipótesis de partida es que la cultura y las tradiciones musicales de cada región se reflejan en las audio features de sus canciones.

IMPORTANTE — Limitación metodológica: este es un análisis **EXPLORATORIO** sobre una muestra **CURADA** y **NO REPRESENTATIVA** de 220 artistas. Las conclusiones son de naturaleza **descriptiva/cualitativa**. No permiten hacer afirmaciones generalizables sobre toda la producción musical de un país o región.

7.1 Metodología

- 220 artistas clasificados manualmente por país y región (curación basada en conocimiento general).
- Criterio de autoría: el 'artista principal' es el primero en el campo artists del dataset.
- 7 regiones definidas: Anglophone, Latinoamérica, España, Asia-Pacífico, Europa (no anglosajona), India, África.
- 11.881 canciones extraídas de tracks_unique.csv con artista principal identificado.
- Comparación estadística: ANOVA de un factor entre regiones para cada audio feature.

7.2 Distribución de canciones y popularidad por región

Región	Canciones	Pop. media	Pop. mediana
Anglophone (USA/UK/AUS/CAN)	5.312	42.0	47
Latinoamérica	2.790	36.2	38
Asia-Pacífico	1.543	43.2	42
Europa (no anglosajona)	1.372	38.5	39
India/Subcontinente	655	48.5	50
España	113	40.4	34
África	96	27.2	2




Fig. 15 — Distribución de popularidad por región (boxplot y medias).

7.3 Perfil sonoro por región




Fig. 16 — Heatmap de audio features por región (valores normalizados 0–1).

Principales hallazgos por región:

- Latinoamérica: danceability=0.605, energy=0.712, valence=0.603. El sonido latino se caracteriza por alta energía y un carácter alegre (valence). Es la diferencia más marcada respecto al resto.
- Asia-Pacífico: instrumentalness=0.099 (moderada), danceability alta. El K-pop y J-pop combinan alta producción electrónica con melodías muy bailables.
- Europa no anglosajona: instrumentalness=0.336 (la más alta). Refleja la presencia de música clásica, EDM instrumental y géneros con menor protagonismo de la voz.
- España: energy=0.758 (la más alta), valence intermedia. El perfil se asemeja más a Latinoamérica que a Europa, con alta energía pero menor valence.
- India: speechiness=0.087 (alta), muchas canciones de Bollywood con letras elaboradas.

7.4 Test de significancia estadística

Feature	F (ANOVA)	p-valor	Significancia
danceability	143.70	< 0.001	***
energy	212.76	< 0.001	***
valence	287.50	< 0.001	***
tempo	21.82	< 0.001	***
acousticness	6.18	0.002	**

Todos los test ANOVA son altamente significativos ($p < 0.001$). Las diferencias sonoras entre regiones no son debidas al azar, sino a características culturales y estilísticas reales de la música de cada zona geográfica.



Fig. 17 — Radares sonoros por región (features normalizadas).




Fig. 18 — Comparativa boxplots: Latinoamérica vs Anglophone vs España en 4 features clave.

8. FASE 6 — TRAYECTORIA TEMPORAL: FEID Y ARTISTAS SIMILARES

Este estudio analiza cómo ha evolucionado el sonido de Feid entre 2018 y 2022, comparándolo con 7 artistas del mismo ecosistema musical (reggaeton urbano latino). La hipótesis es que los artistas del mismo entorno cultural siguen trayectorias sonoras similares, pero cada uno con su propia velocidad e intensidad de cambio.

8.1 Artistas analizados y metodología

Artista	País	Período en dataset	Canciones fechadas
Feid	Colombia	2018–2022	28
J Balvin	Colombia	2014–2022	74
Maluma	Colombia	2016–2022	16
KAROL G	Colombia	2017–2022	27
Ozuna	Puerto Rico	2016–2022	38
Rauw Alejandro	Puerto Rico	2020–2022	19
Daddy Yankee	Puerto Rico	2004–2022	48
Bad Bunny	Puerto Rico	2017–2022	41

Las fechas de lanzamiento se asignan canción por canción a partir del conocimiento discográfico (mes y año de lanzamiento oficial). Cuando el dataset incluye la misma canción en múltiples playlists de compilación (hasta 15 entradas para un mismo tema), se deduplica conservando la versión con mayor popularity.

8.2 Evolución del sonido (todos los artistas)




Fig. 19 — Evolución de danceability, energy, valence y acousticness (media anual por artista).

Tendencias generales observadas entre 2016-2022:

- Danceability: se mantiene alta y estable en todos los artistas (0.70–0.80). El reggaeton es inherentemente bailable y esa característica no varía.
- Energy: ligero aumento en casi todos los artistas a partir de 2020. El trap y el reggaeton urbano de la era post-COVID tiende a producción más agresiva.
- Valence: mayor variación. Bad Bunny baja su valence en sus álbumes más oscuros (X 100PRE, YHLQMDLG) pero sube con Un Verano Sin Ti.
- Acousticness: tendencia decreciente generalizada. La música urbana latina se aleja progresivamente de elementos acústicos hacia producción 100% electrónica.

8.3 Feid vs J Balvin vs Bad Bunny



Fig. 20 — Trayectoria normalizada de Feid, J Balvin y Bad Bunny en 3 features (raw y normalizado).

La comparativa normalizada permite ver la tendencia relativa de cada artista independientemente de sus valores absolutos:

- J Balvin muestra la trayectoria más larga y volátil: arranca en 2014 con un sonido más latinpop (Ay Vamos, Ginza), experimenta con Colores en 2020 (pop/electrónico) y vuelve al reggaeton con JOSE en 2021.
- Bad Bunny presenta grandes saltos por álbum: YHLQMDLG (2020) es su proyecto más bailable y energético; Un Verano Sin Ti (2022) añade variedad con elementos de salsa, dembow y indie que bajan su energía media.
- Feid muestra la trayectoria más lineal y consistente: crecimiento progresivo en danceability y energy desde 2018 hasta 2022, con muy pocas excepciones.

8.4 El sonido colombiano




Fig. 21 — Evolución de Feid, J Balvin, Maluma y KAROL G (4 artistas de Colombia).

Los cuatro artistas colombianos principales muestran convergencia sonora: alta danceability y energy en 2021-2022, con valence alta salvo excepciones. Feid es el que más ha crecido en energía en ese

período, partiendo de niveles más bajos en 2018 (sonido más R&B/melodico) y llegando a valores comparables a J Balvin y Maluma en 2022.

8.5 Popularidad por canción y año (análisis del snapshot)




Fig. 22 — Popularidad de cada canción según su año de lanzamiento. Bad Bunny concentra los valores más altos por el efecto de recencia.

Este scatter confirma visualmente el sesgo de recencia del índice de Spotify: las canciones de 2022 (especialmente del álbum *Un Verano Sin Ti* de Bad Bunny) tienen popularidades muy altas (85–97), mientras que clásicos de Daddy Yankee de 2004-2012 como 'Gasolina' o 'Limbo' tienen popularidades bajas en el snapshot a pesar de ser hits históricos con cientos de millones de reproducciones totales.

8.6 Predicción de la trayectoria sonora de Feid (2023-2025)




Fig. 23 — Extrapolación polinómica del sonido de Feid para 2023-2025. Línea punteada = tendencia; estrellas = predicciones.

Año	Danceability	Energy	Valence	Acousticness	Tempo (BPM)
2018 (inicio)	~0.65	~0.55	~0.50	~0.23	~128
2022 (último)	~0.76	~0.69	~0.62	~0.15	~138
2023 (pred.)	0.747	0.665	0.605	0.140	138.3
2024 (pred.)	0.742	0.671	0.619	0.132	138.8
2025 (pred.)	0.738	0.676	0.633	0.123	139.3

La predicción sugiere una tendencia estabilizadora: danceability ligeramente decreciente, energy y

valence crecientes, acousticness decreciente (más electrónico). El tempo se mantiene estable cerca de los 138-139 BPM.

ADVERTENCIA: estas predicciones son extrapolaciones polinómicas de grado 2 sobre 5 puntos (una media por año), no modelos predictivos robustos. Su valor es ilustrativo de la tendencia reciente de Feid, no una previsión real de su evolución artística. La evolución del sonido de un artista depende de decisiones creativas, productores, tendencias del mercado y colaboraciones que ningún modelo puede anticipar.

9. CONCLUSIONES Y TRABAJO FUTURO

Conclusiones técnicas

- El análisis de audio features de Spotify permite caracterizar géneros musicales y perfiles sonoros con buena fiabilidad estadística, pero su poder predictivo sobre la popularidad es moderado ($R^2 \approx 0.47$). La popularidad en Spotify está dominada por factores de distribución y marketing que los datos de audio no capturan.
- La agrupación de géneros en macro-categorías es imprescindible para obtener resultados clasificatorios interpretables. Los 114 géneros originales son demasiado finos y están solapados, haciendo que el espacio de features sea ambiguo.
- El clustering de canciones por features de audio converge a solo $k=2$ clústeres bien diferenciados (música energética vs. tranquila/acústica). Esto refleja que las audio features de Spotify capturan una dimensión principalmente de 'intensidad sonora' más que la riqueza multidimensional de los estilos musicales.
- Los tres recomendadores implementados demuestran el trade-off entre coherencia y diversidad. El recomendador híbrido es el más apropiado para una app real porque garantiza que las recomendaciones suenan similares (mismo género) pero provienen de artistas distintos (diversidad).

Conclusiones sobre el análisis musical

- Existe una 'identidad sonora' estadísticamente distinguible por región geográfica: la música latina tiene más energy y valence; la música europea más instrumentality. Estas diferencias son robustas ($p < 0.001$) incluso en esta muestra curada.
- La trayectoria de Feid (2018-2022) muestra una evolución coherente hacia el reggaeton urbano de alta energía, paralela a la de sus contemporáneos colombianos (J Balvin, Maluma, KAROL G). Su crecimiento ha sido más rápido y lineal que el de artistas más establecidos.
- El índice de popularidad de Spotify distorsiona cualquier comparación temporal o geográfica. Artistas históricos como Daddy Yankee aparecen con popularidad baja en el dataset a pesar de ser pioneros del género con carrera de 20+ años.

Limitaciones principales

Limitación	Impacto	Mitigación aplicada
popularity es snapshot (recencia)	Alto	Documentado en todos los análisis que la usan
Sin datos de usuarios (filtrado colaborativo)	Medio	Sistema content-based declarado explícitamente
Mapa de macro-géneros ad hoc	Medio	Decisión editorial justificada en la memoria

k=2 en clustering (poca granularidad)	Bajo-Medio	Interpretado como hallazgo, no como limitación del método
Estudio de nacionalidad: muestra curada	Medio	Declarado explícitamente como exploratorio
Predicción con 5 puntos anuales	Alto	Advertencia incluida; presentado como ilustración de tendencia

Trabajo futuro

- Conectar con la API de Spotify para obtener fechas de lanzamiento reales y datos actualizados.
- Añadir filtrado colaborativo con datos de playlists públicas para mejorar la recomendación.
- Profundizar en el análisis de Feid con un estudio de caso completo: todas sus canciones, análisis de letra (NLP), y comparación antes/después de su gran explosión de popularidad.
- Explorar modelos de series temporales más robustos (ARIMA, Prophet) para la predicción de tendencias sonoras con más datos históricos.
- Ampliar el estudio de nacionalidad con datos de más artistas y un muestreo más representativo.

*Informe generado automáticamente a partir de los scripts del proyecto TFG.
Todos los datos, modelos y figuras están disponibles en el repositorio del proyecto.
Junio 2026 · Alfonso García Betico*