



**Inteligencia artificial y
análisis estadístico: estrategias para
la sostenibilidad económica de
clubes deportivos**

Alfonso López Santiago



Inteligencia artificial y análisis estadístico: estrategias para la sostenibilidad económica de clubes deportivos

Alfonso López Santiago

Memoria presentada como parte de los requisitos
para la obtención del título de Grado en Matemá-
ticas por la Universidad de Sevilla.

Tutorizada por

David Orellana Martín
Agustín Riscos Núñez

Índice general

English Abstract	3
Resumen en español	5
1. Introducción	7
1.1. Evolución histórica de la estadística en el fútbol	7
1.1.1. Los Primeros Trazos: El Fútbol como Aritmética Simple (1880-1920)	7
1.1.2. El Hombre que Contaba Balones: Charles Reep y el Método Empírico (1950-1990)	9
1.1.3. La Revolución Digital: Del VHS al Big Data (1990-2020)	11
1.2. El Caso Brentford FC: Cómo el Moneyball del Fútbol Revolucionó las Reglas del Juego	15
1.2.1. Los Pilares del Modelo Brentford	15
1.3. Otros ejemplos de aplicación de la Inteligencia artificial en el mundo del deporte	21
2. Del Análisis Descriptivo a la Predicción: XGBoost y Random Forest en el Fútbol	23
2.1. Análisis descriptivo de los datos	23

II INTELIGENCIA ARTIFICIAL Y ANÁLISIS ESTADÍSTICO: ESTRATEGIAS PARA LA SOSTENIBILIDAD ECONÓMICA DE CLUBES DEPORTIVOS

2.2.	Árboles de clasificación y regresión	25
2.2.1.	Desarrollo	25
2.2.2.	Criterio de división	27
2.2.3.	Poda o recorte de un árbol de regresión	30
2.2.4.	Ventajas y desventajas de los árboles	33
2.2.5.	Ejemplo de un árbol aplicado a predicción de salarios en el mundo del fútbol	33
2.3.	Bagging	34
2.4.	Random Forest	36
2.4.1.	Aplicación de Random Forest en Rstudio: tidymodels	38
2.5.	Método Boosting	39
2.6.	Algoritmo Gradient Boosting	42
2.6.1.	Implementación de XGBoost en Rstudio	43
2.6.2.	Función tune	45
3.	Caso práctico: Análisis y predicción de salarios y taquilla en el mundo del fútbol	47
3.1.	Análisis y predicción de salarios	47
3.1.1.	Obtención y tratamiento de datos	48
3.1.2.	Análisis descriptivo del conjunto de datos	50
3.1.3.	Análisis predictivo de los salarios de la plantilla del Real Betis Balompié	56
3.2.	Análisis y predicción de asistencia a un estadio de fútbol	68
3.2.1.	Obtención y tratamiento de datos	70
3.2.2.	Análisis descriptivo del conjunto de datos	72

3.2.3.	Análisis predictivo de la asistencia al estadio de la Real Sociedad	79
3.2.4.	Construcción de una app Shiny a través de Rstudio	86
4.	Conclusiones	89

Agradecimientos

A mis padres, porque sin ellos no estaría escribiendo esto.

A mis tutores, David Orellana y Agustín Riscos, por su ayuda y por hacer de las reuniones encuentros amenos.

Al fútbol, por ser una razón más para disfrutar de la vida e inspirarme para hacer este trabajo.

English Abstract

This Final Degree Project focuses on the application of artificial intelligence techniques and statistical analysis to contribute to the economic sustainability of sports clubs, with special emphasis on football. Through simpler statistics, graphs, and prediction models such as decision trees or boosting, the issue of player salaries and stadium attendance has been analyzed using real examples from Spanish teams such as Real Betis and Real Sociedad. This can help optimize decisions in areas such as ticket pricing or marketing strategies. Likewise, by addressing the prediction of football players' salaries, the aim is to help clubs make more efficient and financially sustainable signings.

The project reflects how data can complement the intuition and experience of coaches and analysts, without replacing the emotional essence of the sport. Through examples such as graphs and simple metrics, the goal is to bring statistics closer to the average fan, promoting a deeper understanding of the game.

Overall, this Final Degree Project demonstrates that the intelligent use of data can not only improve sports performance but also contribute to more efficient and sustainable economic management for clubs.

Resumen en español

Este Trabajo de Fin de Grado se centra en la aplicación de técnicas de inteligencia artificial y análisis estadístico para contribuir a la sostenibilidad económica de clubes deportivos, con especial énfasis en el fútbol. A través de estadística descriptiva, gráficos y modelos de predicción como árboles de decisión o boosting, se ha analizado la problemática de los sueldos de los jugadores y la asistencia a los estadios de fútbol poniendo ejemplos reales de equipos españoles como el Real Betis y la Real Sociedad. Esto puede ayudar a optimizar decisiones en áreas como la fijación de precios de entradas o estrategias de marketing. Asimismo, abordando la predicción de salarios de futbolistas, se pretende ayudar a los clubes a realizar contrataciones más eficientes y sostenibles en términos financieros.

El proyecto refleja cómo los datos pueden complementar la intuición y experiencia de técnicos y analistas, sin sustituir la esencia emocional del deporte. A través de ejemplos como gráficas y métricas sencillas se pretende acercar la estadística al aficionado medio, fomentando una visión más profunda del juego.

En definitiva, este TFG demuestra que el uso inteligente de los datos no solo puede mejorar el rendimiento deportivo, sino también contribuir a una gestión económica más eficiente y sostenible para los clubes.

1 | Introducción

En este capítulo trataremos la historia de cómo la estadística fue introduciéndose en el mundo del fútbol y la manera en la que ambos ámbitos han crecido hasta convertirse en lo que son a día de hoy.

1.1 Evolución histórica de la estadística en el fútbol

1.1.1 Los Primeros Trazos: El Fútbol como Aritmética Simple (1880-1920)

El 19 de diciembre de 1863, a las afueras de Londres, se disputó el que se reconoce como el primer partido de fútbol de la historia [7]. El Barnes Football Club se enfrentaba al Richmond Football Club, “Football Club” por decir algo, porque no dejaban de ser dos grupos de amigos o compañeros de universidad, que curiosamente terminó con un marcador de 0-0. Después del partido, el Richmond FC, al ver que se trataba de un deporte poco civilizado y organizado decidió dedicarse al rugby. Y eso que este partido se jugó bajo las primeras reglas de la Football Association que nació con el objetivo de unificar las normas del juego. Antes de que surgiese la FA, al no haber una asociación de fútbol como tal, en cada ciudad, pueblo o universidad se jugaba con unas normas distintas, así que cuando se jugaban partidos entre desconocidos estos acababan siendo un caos y un descontrol. No había un acuerdo en los minutos de juego, los fueras de banda, las faltas, ni siquiera en el número de jugadores. Quién le iba a decir a esos chavales del Barnes y del Richmond que más de siglo y medio después, un alumno de la carrera de Estadística en Sevilla iba a estar haciendo su Trabajo de Fin de Grado sobre este maravilloso deporte del que fueron pioneros y le dieron una oportunidad cuando no mucha más gente se la daba.



Figura 1.1: Imagen de la revista National Geographic del Barnes FC vs Richmond FC

Los británicos fueron exportando el deporte a otros lugares del mundo, y a España llegó de la mano de ellos. Marineros, comerciantes y trabajadores británicos comenzaron a practicarlo en ciudades portuarias y zonas industriales, naciendo así en Huelva el primer equipo de fútbol, el Club Recreativo de Huelva. El primer partido en España del que se tienen registros oficiales se jugó el 8 de diciembre de 1889, entre el Recreativo de Huelva y el Rio Tinto Company Limited: un equipo formado por empleados británicos de la mina que se llevó la victoria con un marcador de 0-2.



Figura 1.2: Primer archivo gráfico de la plantilla del Recreativo de Huelva

Para hacernos una idea de lo impredecible que era el fútbol en sus inicios, los primeros equipos utilizaban formaciones como el 1-1-8 (un defensa, un mediocampista y 8 delanteros). Con la popularización de este deporte y el incremento de personas que lo practicaban, fue evolucionando y se convirtió en mucho más organizado y estratégico.

En los inicios del juego, los periódicos sólo registraban goles y alineaciones. La Football League, fundada en 1888, introdujo las primeras tablas de clasificación, pero eran poco más que listas de victorias y derrotas.

En España, al llegar el fútbol más tarde, tardó más en profesionalizarse y por lo tanto el recuento de estadísticas llegó más tarde aún.




Figura 1.3: Representación del sistema 1-1-8

El Athletic Club de Bilbao realizaba el recuento de los goles de sus delanteros, y en 1913, Manuel 'Pichichi' Pagola se convirtió en una de las grandes figuras de la historia del fútbol: el primer goleador reconocido. Su apellido pasó a la historia y todos los niños de hoy en día sueñan con ser el 'pichichi' de su liguilla. Pero los entrenadores de la época no miraban más allá, no se planteaban si era mejor correr o pasar, si había que presionar de una manera u otra... El fútbol se jugaba más con el corazón y con el instinto que con la cabeza, los partidos se convertían en combates a ras del barro.



Figura 1.4: Manuel 'Pichichi' Págola

1.1.2 El Hombre que Contaba Balones: Charles Reep y el Método Empírico (1950-1990)

Todo cambió cuando Charles Reep, un contable obsesionado con el fútbol, se fijó en lo que nadie más se fijaba, comenzó a anotar libreta en mano cada pase, cada tiro fallado, cada balón perdido. Reep, en 1950 viendo un partido del Swindon Town contra el Bristol Rovers se aburría, ya que los locales no conseguían hacerle nada a su rival llegando al descanso 0-0. Fue entonces cuando decidió sacar su libreta y un lápiz y comenzó a anotar cada acción ofensiva que llevaban a cabo los locales, para

así poder sacar conclusiones a posteriori. Tras esto, hubo muchas ocasiones en las que se le podía ver por el campo de su equipo, el Plymouth, con una luz minúscula agarrada a su frente como si de un minero se tratase. [11] Con él comenzaría la era de la estadística en el fútbol. Analizando los datos que tomaba se dio cuenta de lo siguiente:

- **El 80 % de los goles** venían de jugadas de menos de **tres pases**
- **La mayoría de las posesiones** (aproximadamente el 68 % según sus registros) terminaban en pérdida antes de llegar al área rival

Con esta metodología, que empezaba a ser sonada por los campos de las islas británicas, llegó a Brentford en enero de 1951. El equipo marchaba por los puestos finales de Segunda División, cuando Reep entró a formar parte del cuerpo técnico y con sus tácticas lograron pasar del descenso a la décima plaza cosechando 10 victorias en 17 partidos. Luego se trasladó a los Wolves, un equipo más poderoso que el Brentford, donde alcanzó su momento más fructífero consiguiendo importantes logros y siendo reconocido por todo el mundo del fútbol.

Las dos religiones en las que Reep creía eran el POMO (Position of Maximum Opportunity) y el ‘random chance’: lanzar el balón en largo, hacia el lugar de mejor oportunidad, mayor ventaja, y que la aleatoriedad del balón dé sus frutos. Sus conclusiones hicieron que los entrenadores de la época tuviesen claro que el fútbol eficiente era directo, rápido y poco elaborado. Equipos como el Wimbledon FC de los años 80, apodados como ‘Los Locos’, aplicaron sus ideas con éxito, ganando con un estilo antiestético pero muy ofensivo y efectivo.

Reep fue una persona odiada en su momento por la prensa. Su convicción sobre la practicidad de su método e ir en contra de lo que enamoraba a todo el mundo, el juego de posesión, le pasó factura. Así es como estuvo hasta los años 80 sin colaborar con nadie, publicando artículos (“Skill and chance in association football” [10], el primer artículo publicado en un “journal” estadístico sobre el fútbol en toda la historia) hasta que pasó a colaborar con Charles Hughes, director técnico de la FA, en la creación de análisis y tácticas para la selección inglesa.

En definitiva, Reep puede ser catalogado como el primer analista estadístico de la historia del fútbol y el promotor de la presión alta, el juego directo y el pase en largo. Una vida volcada al fútbol: cuando falleció en 2002, y apenas 30 personas fueron a su entierro, se comentó que había visto en toda su vida entre 2200 y 2500 partidos de fútbol.



Figura 1.5: Foto de Charles Reep

1.1.3 La Revolución Digital: Del VHS al Big Data (1990-2020)

El fútbol entraba en la era moderna con una herramienta que revolucionaría la situación: el vídeo. La primera figura relevante fue Arrigo Sacchi cuando entrenaba al AC Milán (1987-1996). El visionario técnico italiano fue pionero en usar grabaciones VHS para estudiar rivales. Sus analistas descomponían cada jugada en cámara lenta, identificando patrones, y así llegó a implementar la defensa en zona basándose en datos de movimientos de jugadores.

Otra personalidad a destacar, cómo no, fue Johan Cruyff y su Dream Team del Barça. Introdujo el concepto de pases efectivos y midió por primera vez el porcentaje de posesión como indicador de su dominio. Sus cuadernos de notas incluían el número de veces que el balón llegaba a Stoichkov (delantero centro del equipo en aquella época) en el área o el número pérdidas en la salida de balón.



(a) Arrigo Sacchi



(b) Johan Cruyff

Figura 1.6: Entrenadores

Con el cambio de milenio nacieron los primeros sistemas de tracking, la década del 2000 trajo consigo tecnología militar adaptada al fútbol. En 1998 surge ProZone, un sistema inglés que usaba cámaras fijas en estadios para rastrear midiendo distancia recorrida por jugadores y realizando mapas de calor de jugadores. El Manchester United de Ferguson fue el primer club en adoptarlo en 2001, ayudándole a obrar grandes exhibiciones en la liga inglesa. En la década del 2010, el Big Data comienza a tomar el control del fútbol. La UEFA implementó sistemas de cámaras de ojo de halcón para rastrear balones y jugadores en 3D. El Liverpool FC fue uno de los primeros clubes que contrató personas ‘ajenas’ al mundo del fútbol para beneficiarse de sus estudios. El director de investigación Ian Graham (doctor en Física) creó modelos para identificar jugadores infravalorados y optimizar los tiros desde fuera del área. Algunas de las métricas son:

- Expected Goals (xG) : Desarrollado por Sam Green (Chelsea FC), calcula la probabilidad de gol basada en la distancia a la portería, el ángulo de tiro y la presión defensiva.
- PPDA (Passes per Defensive Action) : Mide la intensidad en la presión (el Atlético de Madrid lideraba con solo 6 pases rivales permitidos antes de robar).

En el caso de La Liga española, lleva trabajando junto a MediaCoach desde 2014 y cuenta con un sistema de recogida de datos muy amplio permitiendo que los clubes cuenten con todas las métricas y estadísticas que deseen. Uno de los máximos exponentes del Big Data en la liga ha sido Monchi. El que fue director deportivo del Sevilla FC usaba software propio para fichar jugadores con estadísticas de rendimiento en contextos similares. Ahora cada vez más, surge el debate de los datos enfrentados al instinto y al corazón. Las personas más puras y tradicionales cada vez están cediendo más ante el innegable auge del dato y la ayuda que este brinda a los clubes. Métricas en tiempo real en los partidos, que pueden hacer que el técnico cambie detalles del juego al momento, o algoritmos que predicen lesiones, son algunos de los ejemplos de cómo la ciencia puede ayudar en el mundo del fútbol.

Las siguientes declaraciones de dos de los mejores entrenadores de la última década plasman muy bien este debate:

- Jurgen Klopp: "Los números son útiles, pero un partido se gana aquí [señala el corazón]".
- Diego Simeone: "Mis analistas me dicen cuándo presionar, pero la garra no se mide en gráficos".



Figura 1.7: Simeone



Figura 1.8: Klopp

Lo cierto es que, hoy en día, ningún club de élite juega sin un ejército de científicos de datos. El fútbol ya no se entiende sin sus números... aunque todavía se vive con pasión.

14 INTELIGENCIA ARTIFICIAL Y ANÁLISIS ESTADÍSTICO: ESTRATEGIAS PARA LA SOSTENIBILIDAD ECONÓMICA DE CLUBES DEPORTIVOS

Ahora vamos a explicar algunos ejemplos en los que el mundo del dato y el mundo del fútbol se han combinado para cosechar grandes logros, inimaginables para los primeros que practicaban este deporte sin que se les pasara ningún número por la cabeza

1.2 El Caso Brentford FC: Cómo el Moneyball del Fútbol Revolucionó las Reglas del Juego

El término Moneyball nació en el béisbol estadounidense, pero se ha convertido en un concepto universal para describir el uso de análisis de datos y estadísticas avanzadas para competir contra equipos con mayores recursos económicos. Es un enfoque que prioriza las métricas objetivas sobre la intuición o el ojo clínico tradicional para:

- Identificar talentos infravalorados (jugadores con estadísticas excelentes en aspectos clave pero ignorados en el mercado de fichajes, ya que no son muy mediáticos o destacan en características que no llaman tanto la atención).
- Optimizar recursos limitados (comprar barato y vender caro).
- Tomar decisiones basadas en evidencia, no en prejuicios. Por ejemplo, si un jugador aparentemente marca muchos goles, pero se observa que su aportación en el juego no es para nada buena, no dejarse llevar por las emociones.

En 2012, el Brentford FC, un equipo humilde de la League One (la tercera categoría del fútbol inglés), tomó una decisión radical: despedir a todos sus ojeadores tradicionales y confiar exclusivamente en el análisis de datos para construir su plantilla y tomar decisiones burocráticas. Esto se debió a la entrada en el club de Matthew Benham, un multimillonario estadounidense que forjó su riqueza en el mundo de las apuestas deportivas gracias a que desarrolló modelos predictivos basados en datos históricos en divisiones menores de Inglaterra. Graduado en Física en Oxford, fundó Smartodds en 2004 basándose en que el fútbol era predecible si analizabas las variables correctas: no goles o asistencias, sino duelos ganados, pases progresivos y xG en segundas divisiones. Compró el 60 % del club (por 500k libras) cuando jugaba en la tercera división.

1.2.1 Los Pilares del Modelo Brentford

Expected Goals (xG) como filosofía: El xG es un modelo probabilístico que asigna un valor (entre 0 y 1) a cada remate, basado en factores como la distancia a la portería, el ángulo de tiro, el tipo de asistencia o la presión defensiva. En el caso del Brentford, identificaron jugadores con alto xG pero con bajo porcentaje de conversión. Por ejemplo Ollie Watkins en la temporada 2016/2017 jugaba en la cuarta división inglesa; sí,



Figura 1.9: Escudo del BrentFord FC

no lo he escrito mal, la cuarta división inglesa que prácticamente está cerca de no considerarse profesional. Pues bien, fue comprado en 2017 por 2 millones de libras y posteriormente vendido en 2020 por 34 a un equipo de la primera división, incluso llegando a ser convocado por la selección nacional. Ollie Watkins contaba con unos Expected Goals de 0.48 y tenía una media de 1.8 remates a puerta por partido cuando la media de su liga era de 1.2. Además promediaba 6.5 toques en el área rival, lo que demostraba que se posicionaba muy bien. El único problema es que su tasa de conversión a gol (es decir, los goles que anotaba entre todos los tiros a puerta que hacía) era de apenas un 12 % cuando la media de su liga era de un 15 %. Watkins estaba ‘subperformando’ su xG (debería haber marcado más goles según la calidad de sus remates) lo que sugería:

- Oportunidad de mejora: Con mejor entrenamiento de la definición, su rendimiento explotaría.
- Error de mercado: Otros clubes lo veían como un delantero ineficiente por su baja conversión, pero los datos decían que era un asesino posicional.

El algoritmo del club simuló su rendimiento en un equipo con mayor creación de juego (el Brentford dominaba la posesión en la segunda división) y centros más precisos (su xG aumentaría al recibir mejores pase). La predicción concluyó que si Watkins mantenía su volumen de remates pero mejoraba su conversión al 18 %, marcaría 20+

goles por temporada. Así fue, y en la temporada 2019/20 marcó 26 goles siendo el tercer máximo goleador y su xG era de 24.1, así que se confirmó que su rendimiento era sostenible, no suerte. Fue traspasado al Aston Villa por 34M de libras, lo que supuso un beneficio del 1.600 % en tan solo tres años.

A continuación se exponen algunos ejemplos de jugadores que pasaron por el algoritmo del Brentford dejando beneficios admirables:

Ivan Toney

Métrica	Actuación de Toney en la 19/20	Percentil (vs. League One)
Expected Goals(xG)/90	0.68	99 %
Duelos Aéreos Ganados	6,2/90 (73 %)	98 %
Pressuring Actions/90	21.3	95 %
Tasa de Conversión	24 %	91 %

De la tabla se pueden sacar las siguientes conclusiones:

- Esa temporada generó más ocasiones que prácticamente todos sus rivales.
- Dominio físico inusual.
- Domina la presión, realiza muchos esfuerzos por sus compañeros
- Rematador que destaca por su eficiencia.

Dato crucial: Su xG diferencial (xG - goles reales) era de +0.12 lo que indicaba que incluso podía mejorar en un equipo con mejor creación de juego.

Proyección del Algoritmo aplicada a Ivan Toney

El modelo interno del Brentford predijo que, en un equipo como el suyo (con alta posesión y centros al área), Toney:

- Aumentaría su xG/90 a 0.75+ (top 5 % en Championship, la división en la que se encontraba el equipo)
- Podría marcar 25+ goles por temporada.




Figura 1.10: Ivan Toney con la selección inglesa

Behnrama

El modelo de scouting del Brentford detectó en Behnrama patrones únicos para un extremo subutilizado en el Nice de la liga francesa.

Métrica	Valor de Benrahma	Percentil (vs. Ligue 1)
Regates Exitosos/90	4.7	97 %
Expected Assists (xA)/90	0.28	93 %
Pases Progressivos/90	6.3	89 %
Presión en Campo Rival	18.2 acciones/90	85 %

Dato clave: jugó solo 700 minutos en la liga francesa, pero sus estadísticas/90 minutos eran propias de un jugador de élite. El Brentford vio una oportunidad de mercado: un jugador infravalorado por falta de oportunidades.

Proyección del Algoritmo aplicado a Behnrama

El modelo predijo que, en un equipo como el Brentford (con posesión alta y extremos invertidos), Behnrama:

- Aumentaría sus Expected Assists/90 a 0.35+ (top 5 % en la liga del Brentford)
- Podría dar 10+ asistencias y 10+ goles por temporada



Figura 1.11: Behnrama celebrando un gol con el Brentford

Según Benham, ganar o perder no importa, pues aquí la suerte no se tiene en cuenta. La importancia reside en merecer, en rendir según lo esperado y ahí los datos, como los xG, dictan sentencia. Según su director deportivo, las clasificaciones no reflejan lo bueno que es uno. En ocasiones lo es evitando la mirada reveladora de la justicia. Por ello, ignorando cuestiones de azar, el entrenador del Brentford debe rendir según el club estima, aunque su puesto no corresponda a la realidad esperada. Se espera que genere suficientes ocasiones con claridad como para ser un equipo de media tabla. Si se generan, aunque el puesto del equipo en la calificación no sea el esperado, el entrenador tendrá el puesto asegurado. Sin embargo, si salva la categoría o incluso cumple las expectativas, pero sin generar tanto, será destituido.

Otra decisión que el Brentford tomó basándose en los números y no en el corazón fue cerrar su cantera.

El mundo es su cantera

En 2016, el Brentford decidió eliminar su sistema de cantera tras reconsiderar las opciones reales de esta. Esta implicaba 1,5 millones de euros de gasto por temporada en una estructura que solo suponía pérdidas: formaban jugadores de 16-17 años que abandonaban el club por otros más grandes sin suponer beneficios a la entidad. Y es que, a esa edad, los precios de las transferencias son simbólicos, o incluso los jugadores pueden llegar a marcharse libres. Demasiadas pérdidas para un adicto a las cifras. En su lugar, se decidió implementar un modelo que solo supondría beneficios. La vieja estructura tradicional pasó a un único equipo, el Brentford B, formado por descartes de otras grandes canteras nacionales y jugadores ojeados mediante su riguroso algoritmo. Además los contratos en este equipo para jugadores jóvenes son de

apenas dos años de duración. Tiempo suficiente como para disputar un mínimo de 35 partidos estipulados en el mismo, tiempo suficiente para demostrar su valía. Una vez agotado el último segundo del acuerdo, el Brentford podrá extenderlo o, en caso de no cumplir con la filosofía del club, dejarlos marchar sin asumir una sola libra más. Se trata entonces, de una cantera en constante movimiento. Una globalizada, ya que podrá captar talento de cualquier lugar recóndito del mundo.

Yo por ejemplo, como amante del fútbol no estoy de acuerdo con la decisión de cerrar la cantera. Al final, en la cantera formas a jugadores que van a acabar teniendo pasión por los colores de tu club y ese sentimiento de pertenencia y conexión con los aficionados les va a hacer rendir y tomar las riendas en momentos complicados. Además, un gasto de 1,5 millones de libras al año no es un gasto lo suficientemente considerable como para tomar una decisión tan drástica teniendo en cuenta las millonadas que se mueven en el mundo del fútbol. Es verdad que a lo mejor en 2016 ese gasto de 1,5 millones sí influía bastante en los planes del club, pero si yo fuese Benham me plantearía en la actualidad volver a reabrir la cantera. El mejor ejemplo de cantera es la del Barcelona, la famosa ‘masía’. El club atravesaba una situación complicadísima sin precedentes y jugadores jóvenes de la cantera como Lamine Yamal, Pau Cubarsí, Gavi o Fermín están teniendo un papel muy destacado en la vuelta a la cima de este histórico equipo.

Mucha de la información de esta sección la he sacado del periódico online La Media Inglesa. [3]



Figura 1.12: La plantilla del Brentford celebrando su ascenso a la Premier League

1.3 Otros ejemplos de aplicación de la Inteligencia artificial en el mundo del deporte

El FC Barcelona implementó un modelo predictivo para estimar la asistencia al Camp Nou. La inteligencia artificial (IA) analizaba variables como:

- Resultados recientes del equipo.
- Día de la semana y hora del partido.
- Clima pronosticado.
- Precios de las entradas y promociones.

Con estos datos, el club ajustaba estrategias de venta (como descuentos para partidos con baja demanda proyectada), logrando un aumento del 12 % en la ocupación media en temporadas recientes.



Figura 1.13: Estampa del Camp Nou

2 | Del Análisis Descriptivo a la Predicción: XGBoost y Random Forest en el Fútbol

En el caso que incumbe a mi Trabajo de Fin de Grado, he realizado tanto análisis descriptivos como predicciones basadas en algoritmos de inteligencia artificial. En una primera etapa, se llevó a cabo un análisis exploratorio de los datos con el objetivo de identificar patrones, distribuciones y relaciones entre variables. Este análisis descriptivo sirvió como base para comprender la estructura de los datos y orientar la posterior construcción de los modelos.

A partir de estas observaciones iniciales, se aplicaron algoritmos de aprendizaje automático, concretamente XGBoost y Random Forest, con el fin de predecir resultados o métricas clave en el rendimiento futbolístico. Esta combinación metodológica permite no solo describir y entender el comportamiento pasado de los datos, sino también anticipar eventos futuros con base en patrones históricos. El enfoque adoptado busca así aprovechar el poder explicativo de la estadística clásica junto con la capacidad predictiva de los modelos de inteligencia artificial. Mucha de la información referente a los árboles de regresión y los algoritmos boosting la he extraído de [6].

2.1 Análisis descriptivo de los datos

Antes de aplicar modelos predictivos, es fundamental realizar un análisis descriptivo que permita comprender la naturaleza de los datos. Medidas como la media, mediana, desviación estándar y varianza ayudan a identificar tendencias centrales y

dispersión, lo cual es clave para detectar posibles sesgos o valores atípicos.

Visualizaciones como los histogramas permiten observar la forma de la distribución (asimetría, normalidad, etc.), mientras que los boxplots facilitan la detección de outliers y la comparación entre grupos. Estudiar la distribución de las variables ayuda también a decidir si se requieren transformaciones antes de modelar.

Además, el análisis de correlación entre variables permite identificar relaciones lineales que pueden ser relevantes para la predicción. El uso de matrices de correlación o diagramas de dispersión ayuda a detectar multicolinealidad o variables redundantes, y a seleccionar aquellas con mayor potencial explicativo. En conjunto, estas herramientas permiten construir una base sólida para el análisis posterior con algoritmos de aprendizaje automático.

Las siguientes declaraciones de Víctor Orta (director deportivo del Sevilla FC), Sara Carmona (analista de datos para OPTA en LaLiga) y Ramón Rodríguez Verdejo, también conocido como Monchi (director deportivo del Aston Villa) plasman de manera perfecta la importancia de los datos en el mundo del fútbol.

- **Víctor Orta:** “Nunca voy a tomar una decisión solo por los datos, pero nunca voy a tomar una decisión sin tener en cuenta los datos.”
- **Sara Carmona:** “Un entrenador se queda como máximo con el 60 % de las cosas que ocurren en un partido. El dato ha llegado para disminuir riesgo en la toma de decisiones.” Sara Carmona concedió una entrevista muy interesante al podcast Offsiders. [8]
- **Monchi:** “El big data es el futuro del fútbol. No porque vayas a comprar un jugador en función de los datos, sino porque te acorta el espacio de riesgo”.

En definitiva, un buen análisis descriptivo de los datos de un partido o de los datos de un jugador le pueden servir de una ayuda enorme al cuerpo técnico de un equipo para tomar decisiones.



Figura 2.1

2.2 Árboles de clasificación y regresión

Los árboles de clasificación conducen a estratificar o segmentar el espacio predictor en un número de regiones simples, de forma que para predecir una observación determinada se utiliza la media (o la moda) de la región a la que pertenece.

Dado que el conjunto de reglas que se utilizan para segmentar el espacio predictor se puede resumir en un árbol, este tipo de enfoques se conocen como métodos de árboles de decisión.

Los árboles de decisión se pueden aplicar tanto a problemas de regresión, como de clasificación. En este caso nos centraremos en los árboles de regresión aunque se aplica la misma lógica prácticamente para ambos.

Los árboles de regresión dividen el conjunto de datos en grupos o estratos más pequeños y luego ajustan un modelo simple para cada subgrupo: media de la variable objetivo en las observaciones que están dentro del subgrupo (ajuste constante dentro del estrato).

2.2.1 Desarrollo

Un árbol de regresión consiste en una serie de reglas de reparto o división del espacio definido por las variables predictoras.

Ejemplo: Se pretende predecir la variable Y a través de dos variables cuantitativas X_1 (que toma valores positivos) y X_2 (que toma valores entre 0 y 100) y se realiza la partición del espacio predictor $\tilde{X} = \mathbb{R}^+ \times [0, 100]$ recogida en el árbol de la Figura 2.3, donde:

$$\begin{aligned} R_1 &= [0, 204.56) \times [0, 100], \\ R_2 &= [204.56, +\infty) \times [0, 36], \\ R_3 &= [204.56, +\infty) \times [36, 100], \end{aligned}$$

y se predice la variable Y en la región R_j con $\bar{y}(R_j)$ la media muestral de Y en los puntos observados en la región R_j .




Figura 2.2: Árbol de regresión para el ejemplo predictivo

Las regiones R_1 , R_2 y R_3 son conocidas como **nodos terminales** o **hojas** del árbol. Los puntos a lo largo del árbol donde se divide el espacio predictor se conocen como **nodos internos**. Los segmentos del árbol que conectan los nodos se conocen como **ramas**. El árbol de regresión de la figura es una simplificación excesiva de la verdadera relación entre las variables, pero tiene ventajas sobre otros tipos de modelos de regresión: es fácil de interpretar y tiene una representación gráfica fácil e ilustrativa.

Así, un árbol de regresión con J nodos se puede expresar como:

$$f(x) = \sum_{j=1}^J c_j I_{R_j}(x) \quad \text{donde} \quad I_{R_j}(x) = \begin{cases} 1 & \text{si } x \in R_j \\ 0 & \text{c.c.} \end{cases}$$

Si se desea minimizar la suma de cuadrados sobre la muestra (o conjunto de entrenamiento) es inmediato que:

$$\min_{c_1 \dots c_J} \sum_{i=1}^n [y_i - f(x_i)]^2 \Rightarrow \hat{c}_j = \bar{y}(R_j) = \text{media muestral de } Y \text{ en } R_j$$

El error sobre el conjunto de entrenamiento, “error de entrenamiento” o “pérdida de entrenamiento” (*training loss*) es una estimación del error esperado (o riesgo esperado o pérdida esperada, *expected loss*).

$$E[\text{Loss}(Y, f(X))]$$

siendo $\text{Loss}()$ la función pérdida o error seleccionada. En este caso, la suma de errores cuadráticos, es decir, $E[\text{Loss}(Y, f(X))]$ es el error cuadrático esperado. El proceso consta de dos pasos fundamentales:

1. Se construye una partición del espacio predictor en J regiones R_j ($j = 1, \dots, J$)
2. Para cada observación que cae en la región R_j hacemos la misma predicción: la media de los valores de la respuesta para las observaciones de la muestra en R_j

Generalmente, por simplicidad se divide el espacio predictor en rectángulos o cajas, y el objetivo es encontrar las cajas que minimizan la suma de los residuos al cuadrado (RSS):

$$\sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$$

donde $\hat{y}_{R_j}$ es la respuesta media de las observaciones muestrales (muestra de entrenamiento) dentro de la j -ésima caja.

- En cada paso, se hace la división óptima para dicho paso, exclusivamente a través de las observaciones incluidas en cada subgrupo y sin considerar el futuro.

2.2.2 Criterio de división

En cada subgrupo o nodo, para llevar a cabo la división binaria recursiva:

Características del proceso

1. Seleccionamos el predictor X_j y el punto de corte s de tal manera que la división del espacio predictor en las regiones $\{X \mid X_k < s\}$ y $\{X \mid X_k \geq s\}$ conduce a la mayor reducción posible del RSS.

Matemáticamente, consideramos:

$$\text{Reducción de RSS} = \text{RSS}_{\text{padre}} - (\text{RSS}_{\text{hijo izquierdo}} + \text{RSS}_{\text{hijo derecho}})$$

donde:

- $\text{RSS}_{\text{padre}}$ es la suma de residuos al cuadrado antes de la división
- $\text{RSS}_{\text{hijo izquierdo}}$ y $\text{RSS}_{\text{hijo derecho}}$ son las sumas después de la división

Se evalúan todos los predictores $X_1, \dots, X_p$ y todos los posibles puntos de corte s para cada predictor, seleccionando la combinación que maximice la reducción del RSS.

Es decir, tenemos en cuenta todos los predictores $X_1, \dots, X_p$ y todos los valores posibles de punto de corte s para cada uno de los predictores, y se elige el predictor y el punto de corte de manera que el árbol resultante tenga la menor RSS.

Así, para cada k y s se define el par de semiplanos:

$$R_1(k, s) = \{X : X_k < s\} \quad \text{y} \quad R_2(k, s) = \{X : X_k \geq s\}$$

y seleccionamos

$$k, s : \text{minimizan} \sum_{i \in R_1(k, s)} (y_i - \hat{y}_{R_1(k, s)})^2 + \sum_{i \in R_2(k, s)} (y_i - \hat{y}_{R_2(k, s)})^2$$

Encontrar estos valores de k y s puede ser rápido, especialmente cuando el número de características p no es demasiado grande.

A continuación, se repite el proceso, buscando el mejor predictor y el mejor punto de corte con el fin de dividir los datos adicionales a fin de minimizar el RSS dentro de cada una de las regiones resultantes.

Sin embargo, esta vez en vez de dividir todo el espacio predictor, se divide una de las dos regiones previamente identificadas.

Nota: Previo a la primera división, la suma residual de cuadrados o estadístico desviación (deviance) es

$$D = \sum_{i=1}^n (y_i - \bar{y})^2$$

Para la división provocada por la variable X_k y el punto de corte s se tiene

$$D = \sum_{i=1}^n (y_i - \bar{y})^2 = SC_W + SC_B$$

$$SC_W = \sum_{i \in R_1(k,s)} (y_i - \hat{y}_{R_1(k,s)})^2 + \sum_{i \in R_2(k,s)} (y_i - \hat{y}_{R_2(k,s)})^2$$

$$SC_B = n_1(\hat{y}_{R_1(k,s)} - \bar{y})^2 + n_2(\hat{y}_{R_2(k,s)} - \bar{y})^2$$

SC_W = suma de cuadrados dentro de los grupos (desviación tras la división)

SC_B = suma de cuadrados entre los grupos

Así,

$$\min_{k,s} SC_W(k, s) = \min_{k,s} [D - SC_B(k, s)] \iff \max_{k,s} SC_B(k, s)$$




Figura 2.3

El proceso descrito puede producir buenas predicciones sobre la muestra de entrenamiento, pero es probable que **sobreajuste** los datos, conduciendo a un rendimiento pobre, debido a que el árbol resultante puede ser demasiado **complejo**.

Un árbol **más pequeño** con un menor número de divisiones podría conducir a menor varianza y mejor interpretación a costa de un leve aumento de sesgo.

Elementos necesarios en un árbol de regresión

1. Un conjunto de cuestiones binarias para hacer las divisiones
2. Un criterio para evaluar la bondad de las divisiones
3. Una regla de parada *En principio podría lograrse un árbol con un nodo final por cada observación, pero en tal caso se obtiene un modelo muy complejo*
4. Una regla para predecir en cada nodo terminal

2.2.3 Poda o recorte de un árbol de regresión

Un árbol menos complejo (menor número de divisiones o nodos) podría conducir a menor varianza a costa de un leve aumento del sesgo. La estrategia más usada es construir un árbol y a continuación se recorta o se poda obteniendo un sub-árbol.

Cualquier árbol $T \subset T_0$ que puede obtenerse recortando T_0 (es decir, colapsando cierto número de nodos terminales) recibe el nombre de sub-árbol.



Figura 2.4: Diagrama de poda de árboles

¿Cómo podemos determinar la mejor manera de podar el árbol?

Haremos una colección de árboles podados y seleccionaremos el mejor árbol entre todos los incluidos en la colección. El objetivo es seleccionar uno de los árboles de la secuencia de árboles podados. Concretamente, se trata de asociar una medida de error o de coste a cada árbol T de la secuencia y escoger aquel que tenga asociado el menor error, o bien, aquel subárbol que tenga un error muy similar al óptimo pero con un tamaño (o complejidad) menor.

Elegir $T^{(k_0)}$: $C(T^{(k_0)}) = \min_k C(T^{(k)})$ con

$$C(T) = \sum_{j=1}^{|T|} \sum_{x_i \in R_j} (y_i - \hat{y}_{R_j})^2 = C(T, 0)$$

Problema: Estimación honesta del coste de poda

¿Cómo estimar "honestamente" $C(T^{(k)})$? Dos soluciones posibles son:

Dos soluciones posibles son:

- $C_{ts}(T)$, estimador por conjunto de prueba (test set), que se calcula dividiendo el conjunto de aprendizaje D en dos subconjuntos disjuntos, aprendizaje D_L y test D_T . Su aplicación consiste en:
 - Se obtiene un árbol T_0 inicial con D_L y se obtiene la secuencia de árboles a través del procedimiento de poda: $T_0 \supseteq T^{(1)} \supseteq T^{(2)} \supseteq \dots \supseteq T^{(k)} \supseteq \dots$

- Con el conjunto D_T se obtiene la secuencia $C_{ts}(T^{(k)})$. El árbol óptimo será

$$T^{(k_0)} : C_{ts}(T^{(k_0)}) = \min_k C_{ts}(T^{(k)})$$

- $C_{cv}(T)$, estimador por validación cruzada. Suele utilizarse validación cruzada con $K = 10$ pliegues o iteraciones. En la validación cruzada de K pliegues (K -fold cross-validation), el conjunto de datos D se dividen en K subconjuntos. Uno de los subconjuntos se utiliza como datos de prueba y el resto ($K - 1$) como datos de entrenamiento.

El proceso de validación cruzada es repetido durante K iteraciones, con cada uno de los posibles subconjuntos de datos de prueba. En este caso, $C_{cv}(T)$ se obtiene como media de las M medidas obtenidas a través de las iteraciones. Su aplicación es igual que la anterior.

Para evitar la inestabilidad de un estimador de este tipo resulta recomendable calibrar la incertidumbre de $C_{ts}(T)$ y $C_{cv}(T)$ calculando su error estándar (SE). Se define el error estándar asociado al estimador $C_{ts}(T)$, o $C_{cv}(T)$, como:

Los estimadores de $C(T)$ en función del número de nodos terminales, $|T^{(k)}|$, se comportan de manera similar a la figura: rápido decrecimiento inicial seguido de un largo valle, casi plano, y un posible crecimiento leve para valores altos de $|T^{(k)}|$. Esto se puede observar en la Figura 2.5.




Figura 2.5: Comportamiento de los estimadores $C(T)$ en función del número de nodos terminales

Así, el mínimo es muy inestable, por lo que se propone la regla 1-SE como alternativa a la selección propuesta del mínimo con el objetivo de reducir esta inestabilidad

a la vez que nos aseguremos que el árbol seleccionado sea el más simple con valor criterio cercano a dicho mínimo.

Error estándar de los estimadores

Para evitar inestabilidad, se recomienda calcular el error estándar:

$$SE(C_{ts}(T)) \quad \text{y} \quad SE(C_{cv}(T))$$

donde SE representa el error estándar asociado a cada estimador.

2.2.4 Ventajas y desventajas de los árboles

Los árboles de decisión para la regresión y clasificación tienen un número de ventajas sobre los enfoques más clásicos:

- ▲ Los árboles son muy fáciles de explicar, incluso más que la regresión lineal
- ▲ Los árboles de decisión reflejan más de cerca la toma de decisiones humanas al seguir pautas similares
- ▲ Los árboles se pueden visualizar gráficamente, y son fáciles de interpretar, sobre todo si son pequeños
- ▲ Los árboles pueden manejar fácilmente predictores cualitativos sin la necesidad de crear variables ficticias y las posibles interacciones se incluyen automáticamente
- ▲ Los resultados son invariantes a transformaciones monótonas de las variables predictoras
- ▲ En conjuntos de datos grandes puede revelar estructuras complejas
- ▲ Es una metodología no paramétrica

2.2.5 Ejemplo de un árbol aplicado a predicción de salarios en el mundo del fútbol

Representación Gráfica con Términos Técnicos

[Nodo Raíz: RSS = 58.7B]

[División: Goles 12?] → Maximiza reducción de RSS
[Nodo Sí: RSS = 18.3B] → ¿Asistencias 18?
[Nodo Sí: Salario = 8.2 M€] (RSS = 8.1)
[Nodo No: Salario = 5.0 M€] (RSS = 8.3)
[Nodo No: RSS = 8.33] → ¿Intercepciones 8?
[Nodo Sí: Salario = 1.5 M€] (RSS = 8.0)
[Nodo No: Salario = 2.2 M€] (RSS = 1.5)

- **Nodos terminales:** Regiones R_j donde las predicciones son constantes ($\hat{y}_{R_j}$)

Ejemplo con jugador ficticio "Felipe Torres"

Datos:

- Goles = 18
- Asistencias = 9
- Intercepciones = 4

Recorrido por el árbol:

1. **Nodo Raíz:** ¿Goles ≥ 12 ? → Sí (reduce RSS al separar goleadores)
2. **Nodo Goles ≥ 12 :** ¿Asistencias ≥ 10 ? → No (RSS mínimo en este contexto)
3. **Predicción:** Salario = 5.0 M€ (media de jugadores en $R_2 = \{\text{Goles} \geq 12, \text{Asistencias} < 10\}$)

2.3 Bagging

Bagging es un procedimiento de uso general para la reducción de la varianza de un método de aprendizaje estadístico, muy útil y de uso frecuente en el contexto de árboles de decisión.

Idea básica: dado un conjunto de n observaciones independientes $Z_1, \dots, Z_n$, de una población con varianza σ^2 , la varianza de $\bar{Z}$ es σ^2/n . Es decir, el promedio reduce la varianza. En consecuencia, una forma natural de reducir la varianza (aumentar la precisión de la predicción) de un método de aprendizaje estadístico es tomar muchos

conjuntos de aprendizaje, construir un modelo de predicción por separado usando cada conjunto, y considerar el promedio de las predicciones resultantes.

Se considera la estrategia **bootstrap**:

- se generan B muestras bootstrap (*muestras obtenidas de la original a través del muestreo con repetición*), es decir, B subconjuntos de entrenamiento,
- se estiman para cada uno de ellos el objetivo $\hat{f}^{*1}(x), \hat{f}^{*2}(x), \dots, \hat{f}^{*B}(x)$, y
- para obtener un modelo único de aprendizaje estadístico de baja varianza, se considera

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$$

- El método bagging, en general, mejora las predicciones de los métodos de regresión.
- En el método bagging, los algoritmos o técnicas se agregan “en paralelo”.
- Para árboles de regresión, se construyen B árboles, y se considera el promedio de las predicciones resultantes.
- Estos árboles no se podan. De ahí que cada árbol tiene una alta varianza, pero bajo sesgo. Promediando estos B árboles se reduce la varianza.
- En el contexto de clasificación (variable objetivo Y cualitativa) existen diversos enfoques posibles, pero el más simple es el siguiente: dada una observación de prueba, se registran las B clases asignadas en cada uno de los árboles y se considera el voto mayoritario, es decir, la asignación general se realiza a la clase más frecuente.

En pocas palabras el bagging consiste en promediar muchos modelos para mejorar la precisión.

Ejemplo: Si un árbol individual predice salarios con alta variabilidad, el bagging promedia 100 árboles entrenados en muestras distintas, suavizando errores.




Figura 2.6: Lógica detrás del Bagging

2.4 Random Forest

Al igual que en el *bagging*, se construye una serie de árboles sobre muestras de entrenamiento *bootstrap*. Pero en la construcción de estos árboles, cada vez que se va a realizar una división de un nodo, no se realiza seleccionando el predictor en el conjunto total de p predictores, sino que **se utiliza una muestra aleatoria de m ($m \leq p$) predictores**.

El parámetro m se puede seleccionar mediante las técnicas habituales de validación cruzada. Por lo general se elige:

- $m \approx \sqrt{p}$ (para problemas de clasificación)
- $m = \frac{p}{3}$ (para problemas de regresión)

En resumen, el método de bosques aleatorios consiste en aplicar *bagging*:

- usando árboles de decisión como predictores
- contruidos eligiendo en cada nodo el mejor predictor entre una muestra aleatoria de m atributos
- sin podar los árboles resultantes

Aunque pueda parecer inadecuado usar tan sólo un subconjunto de m predictores, en lugar de todos ellos, esta estrategia tiene una razón de ser:

Supongamos que hay **un predictor muy fuerte** en el conjunto de datos, junto con un número de otros predictores **moderadamente fuertes**. En la colección de árboles *bagging*, la mayoría o la totalidad de los árboles utilizará este predictor en la división superior o primera. Y posteriormente, los otros predictores moderadamente fuertes.

En consecuencia, *todos los árboles serán bastante similares entre sí*. Y, por tanto, las predicciones de los árboles estarán altamente correladas.

- Un **promedio de muchas cantidades altamente correladas** no conduce a una reducción grande de la varianza como ocurre con un promedio de muchas cantidades no correladas.
- Esto significa que el *bagging* no dará lugar a una reducción sustancial de la varianza en esta configuración.

El uso de un pequeño valor de m en la construcción de un bosque aleatorio será útil cuando tenemos:

- Un gran número de predictores
- Predictores correlacionados entre sí

Ejemplo con Futbolistas

Variables: Goles, Asistencias, Intercepciones, Edad.

Árboles:

1. Goles + Asistencias $\rightarrow$ 6.0 M€

2. Intercepciones + Edad $\rightarrow$ 5.5 M€

3. Goles + Edad $\rightarrow$ 6.2 M€

Predicción: $(6.0 + 5.5 + 6.2)/3 = 5.9$ M€

En Pocas Palabras

Random Forest = Bagging + Aleatoriedad en predictores



Modelos más robustos y precisos

2.4.1 Aplicación de Random Forest en Rstudio: tidymodels

```
rf_model <- rand_forest(  
  mtry = floor(sqrt(ncol(train_data)-1),  
  trees = 500,  
  min_n = 2  
) %>%  
  set_engine("ranger", importance = "impurity") %>%  
  set_mode("classification")
```

- **trees = 50:** Número de árboles en el bosque.
 - ¿Por qué 50?: Es un valor inicial típico para pruebas rápidas. En producción suelen usarse 500+ para mayor precisión.
- **mtry = floor(sqrt(ncol(train) - 1)):** Número de variables aleatorias consideradas en cada división.
 - Cálculo: $\sqrt{n_{\text{predictores}}}$ es una regla común para clasificación (en regresión suele usarse $n_{\text{predictores}}/3$).
 - Ejemplo: Si hay 9 predictores, $mtry = \text{floor}(\sqrt{9}) = 3$.
 - Objetivo: Asegurar diversidad entre árboles (evitar que todos usen las mismas variables).
- **min_n = 5:** Mínimo de observaciones requeridas en un nodo para dividirlo.
 - Efecto: Controla el sobreajuste (a mayor valor, árboles más simples).

Cálculo de importancia de las variables

Dentro de `set_engine` a la hora de señalar "importance" podremos señalar `impurity` o `permutation`, depende de como queramos que se realice el cálculo de la import-

nancia de las variables

importance = "impurity"

- Mide la **reducción total en la impureza** (usando el índice de Gini o RSS) que genera cada variable al dividir nodos en todos los árboles.
- Variables con mayor reducción promedio son más importantes.

importance = "permutation"

- **Qué hace:**
 - Aleatoriza los valores de una variable (ej: mezcla goles) y mide cuánto **empeora el rendimiento** del modelo (en RMSE o precisión).
 - Si el error aumenta mucho, esa variable es crítica.
- **Ejemplo:**
 - Si al mezclar goles el RMSE sube un 20 %, su importancia es alta.

```
vip::vip(modelo)
```

2.5 Método Boosting

El método **boosting** permite mejorar la precisión en la clasificación mediante la combinación de modelos predictivos de Aprendizaje Automático. Se construyen múltiples modelos del mismo tipo, sobre los mismos datos de entrenamiento, cambiando los pesos de cada caso. Cada modelo trata de mejorar las predicciones erróneas de los modelos anteriores.

- Los clasificadores se construyen **secuencialmente**. Cada clasificador se enfrenta usando información del clasificador construido previamente.
- El conjunto de entrenamiento para la construcción de cada clasificador se obtiene mediante **muestreo ponderado**.
- Las instancias mal clasificadas en una iteración tienen **mayor probabilidad** de ser seleccionadas en la siguiente.
- La construcción de cada clasificador depende **fuertemente** de los clasificadores previamente construidos.

- Se sustenta en dos principios fundamentales:
 - Ningún clasificador es siempre el mejor
 - La combinación de clasificadores débiles puede suavizar las carencias individuales, produciendo un clasificador más eficiente




Figura 2.7: Boosting

- Extraer un conjunto E1 sin reemplazamiento de la muestra de aprendizaje. Utilizar E1 para entrenar un clasificador C1.
- Extraer un segundo subconjunto E2 sin reemplazamiento de la muestra de aprendizaje y añadir el 50 % de las instancias mal clasificadas anteriormente. Utilizar E2 para entrenar un clasificador C2.
- Encontrar el subconjunto E3 de instancias de la muestra de aprendizaje en las que difieren los clasificadores C1 y C2. Utilizar E3 para entrenar un clasificador C3.
- Combinar los clasificadores C1, C2 y C3 mediante votación propia.




Figura 2.8: Boosting

Algoritmo AdaBoost

AdaBoost es el abuelo de los métodos boosting.

1. Inicializar los pesos de las observaciones:

$$w_i = \frac{1}{n} \quad \text{para } i = 1, \dots, n$$

2. Para $m = 1$ hasta M (número de iteraciones):

a) Obtener un clasificador $C_m(x)$ usando los pesos w_i y calcular el error:

$$\epsilon_m = \sum_{\substack{i \\ y_i \neq C_m(x_i)}} w_i$$

Suma de los pesos de las observaciones mal clasificadas

b) Si $\epsilon_m \geq \frac{1}{2}$, **TERMINAR**. (α_m sería negativo)

c) Calcular el peso del clasificador:

$$\alpha_m = \frac{1}{2} \ln \left(\frac{1 - \epsilon_m}{\epsilon_m} \right)$$




Figura 2.9: Boosting

d) Actualizar los pesos:

$$w_i = w_i \cdot e^{-\alpha_m C_m(x_i)y_i} \quad \text{para } i = 1, \dots, n$$

e) Normalizar los pesos:

$$w_i = \frac{w_i}{\sum_{j=1}^n w_j}$$

3. Clasificador final:

$$C(x) = \text{sign} \left[\sum_{m=1}^M \alpha_m C_m(x) \right]$$

2.6 Algoritmo Gradient Boosting

La librería XGBoost como su nombre indica (Extreme Gradient Boosting) se basa más específicamente en el algoritmo Gradient Boosting, que es una generalización del

método boosting basado en la minimización de una función de pérdida diferenciable arbitraria. Enfocada a resolver problemas de regresión, aunque puede adaptarse a la resolución de problemas de clasificación.

1. Inicializar el modelo:

$$F_0(x) = \arg \min_{\alpha} \sum_{i=1}^n L(y_i, \alpha)$$

2. Para $m = 1$ hasta M :

a) Calcular los pseudo-residuos:

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad \text{para } i = 1, \dots, n$$

Los pseudo-residuos son los gradientes negativos de la función de pérdida respecto a las predicciones actuales. Indican la dirección en la que el modelo debe ajustarse para reducir el error.

b) Ajustar un clasificador base $h_m(x)$ a los pseudo-residuos:

Entrenar $h_m(x)$ usando $\{(x_i, r_{im})\}_{i=1}^n$

c) Calcular el paso de búsqueda α_m :

$$\alpha_m = \arg \min_{\alpha} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \alpha h_m(x_i))$$

d) Actualizar el modelo:

$$F_m(x) = F_{m-1}(x) + \alpha_m h_m(x)$$

2.6.1 Implementación de XGBoost en Rstudio

```
model_xgb <- boost_tree(
  trees = 100,      # Número de árboles
  tree_depth = 3,   # Profundidad máxima de cada árbol
  learn_rate = 0.1, # Tasa de aprendizaje (eta)
  mtry = 3,         # Variables aleatorias por división
  min_n = 5,        # Mínimo observaciones en nodos terminales
```

```
loss_reduction = 0.01 # Reducción mínima de pérdidas (gamma)
) %>%

set_engine("xgboost") %>% # Motor XGBoost
set_mode("classification") # Modo clasificación
```

1. **trees = 100**

Es el número total de árboles débiles (modelos base) que se construyen en el proceso de boosting.

Se elige dependiendo de la complejidad del problema. Un número demasiado bajo causaría un modelo subajustrado (no captura patrones) mientras que un modelo demasiado alto puede tener riesgo de sobreajuste.

2. **tree_depth = 3** (Profundidad máxima de cada árbol)

Es el número máximo de niveles que puede tener cada árbol.

Se suelen elegir valores típicos entre 3-10 dependiendo de la complejidad del problema.

3. **learn_rate = 0.1**

Es el peso asignado a la contribución de cada árbol en la actualización del modelo. Controla cuánto aprende el modelo en cada paso.

Los valores típicos suelen ir de 0.01 a 0.3. Un valor bajo es más preciso pero requiere más árboles (lo que implica lentitud). Un valor alto converge rápido pero no asegura la misma precisión.

Si el learn rate es bajo conviene aumentar los trees para compensar.

4. **mtry = 3** (Variables aleatorias por división)

Número de variables consideradas en cada división del árbol (similar a Random Forest).

Cómo se elige:

- Valores típicos: Entre 1 y el número total de características
- **Valor bajo:** Mayor aleatoriedad (reduce sobreajuste, útil para alta dimensionalidad)
- **Valor alto:** Menos aleatoriedad (mejor para pocas variables)
- **Regla práctica:** Usar $\sqrt{n_{\text{variables-predictoras}}}$ o $n_{\text{variables-predictoras}}/3$

5. **min_n = 5** (Mínimo de observaciones en nodos terminales)

Número mínimo de muestras requeridas en una hoja (nodo final) del árbol.

Cómo se elige:

- Valores típicos: Entre 1 y 10
- **Valor bajo:** Árboles más complejos (riesgo de sobreajuste)

- **Valor alto:** Árboles más robustos (evita splits con pocos datos)
 - **Ejemplo:** min_n = 5 evita hojas con menos de 5 muestras
6. **loss_reduction = 0.01** (Reducción mínima de pérdidas, gamma)
Umbral para realizar una división en el árbol. Una división sólo se realiza si reduce la pérdida al menos en este valor.

Cómo se elige:

- Valores típicos: Entre 0 y 0.5
- **Valor bajo:** Permite más divisiones (árboles complejos)
- **Valor alto:** Produce árboles conservadores (menos splits, modelo más simple)
- **Nota:** Valores altos previenen sobreajuste pero pueden causar subajuste

2.6.2 Función tune

Lo más inteligente es usar la función tune. Con la función tune creamos una cuadrícula de búsqueda de manera que entrenamos al modelo con cada combinación de hiperparámetros y evalúa su rendimiento en los pliegues de validación cruzada.

```
# Modelo con parámetros para tunear
model_xgb <- boost_tree(
  trees = tune(),          # Número de árboles (50-150)
  tree_depth = tune(),    # Profundidad (3-6)
  learn_rate = tune()     # Tasa de aprendizaje (0.01-0.1)
) %>%
  set_engine('xgboost') %>%
  set_mode('classification')

# Cuadrícula de búsqueda
grid <- grid_regular(
  trees(range = c(50, 150)),
  tree_depth(range = c(3, 6)),
  learn_rate(values = c(0.01, 0.1)),
  levels = 2
)

# Validación cruzada 5-fold
```

```
xgb_folds <- vfold_cv(train_data, v = 5)

# Búsqueda de parámetros
tune_results <- tune_grid(
  object = model_xgb,
  preprocessor = recipe_xgb,
  resamples = xgb_folds,
  grid = grid,
  metrics = metric_set(accuracy)
)

# Mejores parámetros
best_params <- select_best(tune_results, metric = "accuracy")
final_model <- finalize_model(model_xgb, best_params)

# Entrenamiento final
final_fit <- final_model %>%
  fit(Species ~ ., data = train_data)
```

El modelo probaría con todos esos hiperparámetros y nos devolvería la mejor combinación. Al probar varios modelos obviamente va a tardar más en darnos una respuesta pero merecerá la pena sabiendo que se obtiene el mejor modelo posible.

He aprendido mucho acerca de modelos y su respectiva aplicación a Rstudio en la página web DataCamp. [2] También gracias la asignatura de IA que estoy cursando en este mismo cuatrimestre.

3 | **Caso práctico: Análisis y predicción de salarios y taquilla en el mundo del fútbol**

A lo largo de este trabajo hemos explorado las bases teóricas y metodológicas de distintos modelos de inteligencia artificial aplicados al ámbito deportivo. Para poner en práctica estos conocimientos, he decidido centrarme en dos aspectos clave de la gestión de un club de fútbol: la predicción de salarios de los jugadores y la estimación de la asistencia al estadio. Este análisis no solo servirá para validar los modelos tratados (como Random Forest y XGBoost), sino también para extraer conclusiones prácticas que podrían ser útiles para la toma de decisiones de un club. ¿Qué variables influyen más en el salario de un jugador? ¿Cómo afecta el rendimiento del equipo a la asistencia de público? Estas son algunas de las preguntas que guiarán nuestro estudio.

3.1 **Análisis y predicción de salarios**

Para esta parte del trabajo se ha utilizado un conjunto de datos obtenido de la plataforma Kaggle, que recopila estadísticas de rendimiento de los jugadores de La-Liga como goles, asistencias, minutos jugados, entre otras métricas individuales (las veremos en profundidad más adelante).

A partir de esta información llevaremos a cabo un análisis tanto descriptivo como predictivo que permita estimar el salario que le correspondería a cada jugador en función de su rendimiento. Este análisis se ha centrado en la plantilla del Real Betis Balompié, con el fin de contrastar los salarios reales con los estimados por el modelo.

De este modo, es posible identificar qué jugadores están rindiendo por encima o por debajo de lo que su salario sugiere, aportando así una herramienta útil para la gestión deportiva y la planificación económica del club.

La información sobre los salarios la he obtenido a través de Capology.

3.1.1 Obtención y tratamiento de datos

Como ya he dicho anteriormente, los datos sobre el rendimiento de los jugadores los he obtenido a través de Kaggle [12] y los datos sobre sus salarios a través de Capology [1]. Me llevó un buen trabajo asignarle a los jugadores uno a uno su salario. Podía haber seguido otras técnicas que probablemente me hubieran ahorrado algo de tiempo como hacer "web scraping" (obtener datos directamente desde la página web en la que están presentados) y haber hecho algún tipo de joint con los datos sobre el rendimiento, pero a la altura del cuatrimestre en la que estaba realizando esta parte del trabajo no tenía los conocimientos necesarios.

La dimensión de mi base de datos es de 511x151, es decir 151 variables de 511 jugadores distintos, pero no se va a poder contar con todos los jugadores para el estudio ya que hay algunos de los que no se conoce su sueldo u otras variables, o bien por que no han disputado prácticamente ningún partido o bien porque canteranos que aparecen como jugadores de LaLiga pero ni han llegado a debutar. En otras variables en vez de aparecer 0 aparecen NA, por lo que vamos a imputar los NA como ceros. Hay otras maneras de imputar los NA, pero en mi caso he decidido hacerlo de esta manera ya que si un jugador ha marcado un total de cero goles se "merece" que el valor en su caso de la variable gol sea un 0, y no la media de los jugadores de su posición por ejemplo.

Por lo que la primera parte de nuestro estudio será preparar los datos para que nada nos impida poder realizar nuestro análisis sin ningún problema.

Quitando los jugadores de los que se desconoce su salario (el valor del salario es NA) nos quedamos con 342 jugadores. Puede parecer, y de hecho lo es, un conjunto de datos bastante pequeño. Pensé en añadir también jugadores de otras ligas, pero esto no tendría sentido ya que cada liga de Europa se comporta de una manera diferente y cada una tiene una estructura salarial distinta. Los sueldos mínimos no son los mismos, los equipos no tienen la misma capacidad económica por lo que no sería inteligente mezclar a jugadores de distintas ligas en un mismo modelo. Por ejemplo,

los salarios de la liga inglesa son muy elevados mientras que aquí un jugador de un equipo de la parte de abajo de la tabla puede cobrar menos de 200k euros.

Estudio de las variables

El conjunto de datos con el que hemos trabajado tiene algunas variables que no nos interesan en absoluto como por ejemplo: competición, peso, instagram, etc. Por esta razón, vamos a seleccionar las variables que consideremos importantes para llevar a cabo el estudio que queremos realizar.

Para empezar, se van a prescindir de los porteros y de las variables relacionadas con esta posición, ya que no tienen nada que ver con los jugadores de campo. Se van a seleccionar las siguientes variables:

- `Salary` — Salario del jugador
- `nickname` — Nombre informal o apodo
- `team.shortname` — Nombre corto del equipo
- `date_of_birth` — Fecha de nacimiento
- `position` — Posición en el campo
- `goals` — Goles anotados
- `assists_intentional` — Asistencias intencionadas
- `time_played` — Tiempo total jugado
- `tackles_won` — Entradas ganadas
- `international` — Si ha sido internacional
- `shots_on_target_inc_goals` — Tiros a puerta (incluye goles)
- `duels_won` — Duelos ganados
- `key_passes_attempt_assists` — Pases clave / intentos de asistencia
- `blocks` — Bloqueos realizados
- `forward_passes` — Pases hacia adelante
- `appearances` — Apariciones (partidos jugados)
- `aerial_duels_won` — Duelos aéreos ganados
- `open_play_passes` — Pases en jugada abierta
- `games_played` — Partidos jugados
- `successful_dribbles` — Regates exitosos
- `successful_long_passes` — Pases largos exitosos
- `hit_woodwork` — Disparos al poste
- `successful_passes_own_half` — Pases exitosos en campo propio

- `successful_passes_opposition_half` — Pases exitosos en campo contrario
- `clean_sheets` — Partidos sin goles encajados
- `total_clearances` — Despejes realizados
- `total_fouls_won` — Faltas recibidas
- `total_touches_in_opposition_box` — Toques en el área rival

3.1.2 Análisis descriptivo del conjunto de datos

A continuación, se presentarán una serie de gráficos que he considerado interesantes para comprender en profundidad la estructura de los salarios de los jugadores. He realizado un análisis exploratorio basado en visualizaciones clave. Este estudio incluye:

- El análisis de **correlaciones** entre el salario y múltiples variables de rendimiento y características de los jugadores, con el fin de identificar qué factores están más relacionados con la remuneración económica.
- La elaboración de **histogramas** y **diagramas de caja (boxplots)** que permiten observar la distribución de los salarios en función de variables como la experiencia internacional, la posición en el campo o el equipo al que pertenece el jugador.
- El estudio de **medidas de dispersión y tendencia central**, como la desviación estándar, la media y la mediana, para evaluar la variabilidad y simetría en los salarios.
- La detección de **jugadores con bajo tiempo de juego pero alto rendimiento ofensivo**, lo cual puede ser útil para identificar perfiles con potencial infravalorado.
- Visualizaciones que facilitan la comparación entre distintos grupos de jugadores y ayudan a interpretar mejor las posibles **inequidades o patrones de valorización** en el mercado.

Estas representaciones gráficas no solo aportan claridad visual a los datos, sino que también sirven como punto de partida para reflexiones más profundas sobre cómo se determina el salario en función del rendimiento, la posición y otras características individuales.

Estudios más ajenos a la cuestión salarial

Se van a exponer dos ejemplos en los que el director deportivo de un club podría usar la estadística y la representación gráfica de esta para obtener métricas muy interesantes de jugadores




Figura 3.1: Asistencias y regates exitosos

El jugador en la esquina superior derecha, que como bien indica el gráfico es el jugador que presenta una relación entre goles y asistencias más alta, es Savinho. Pues bien, este jugador fichó el verano pasado por el Manchester City por un precio superior a 50 millones de euros.

Mediante esta tabla hemos querido estudiar a jugadores que por distintos motivos no gozan de muchos minutos en sus clubes, por lo que podrían ser jugadores interesados en buscar nuevas oportunidades en otros equipos, y al gozar de pocos minutos podrían salir por un precio más bajo. Esta tabla refleja perfectamente el por qué la estadística sola no es suficiente y también hay que entender de fútbol. Raphinha y Pedri estuvieron lesionados y ese es el motivo por el que disputaron tan pocos minutos. Sin embargo, Trejo, Barrene, Riquelme y Carlos Vicente son suplentes en sus equipos y podrían ser suculentas oportunidades de mercado.

Top 10 jugadores con alto impacto ofensivo y pocos minutos jugados							
Jugador	Salario	Minutos jugados	Goles	Asistencias	Pases clave	Regates exitosos	Impacto ofensivo
Raphinha	12.500.000	1371	6	9	32	24	71
Pedri	9.380.000	1482	4	2	35	16	57
Lucas V.	9.380.000	1410	3	5	24	24	56
Trejo Jp	510.000	1381	0	0	23	33	56
Barrene	1.560.000	1436	4	1	12	38	55
Riquelme	620.000	1522	3	5	23	24	55
Carlos V.	450.000	1118	2	4	29	15	50
Lukébakio	3.000.000	1124	5	0	12	32	49
Sadiq	1.200.000	1076	3	0	9	31	43
Juanlu	250.000	1174	0	2	15	25	42

Figura 3.2: Jugadores con alto impacto ofensivo y pocos minutos jugados

La cuestión del salario

Vamos a empezar con varios datos muy simples al alcance de cualquier persona con nociones básicas de estadística, pero que ayudan a comprender muy bien la variable sobre la que vamos a centrar este estudio: el salario.

- **Media del salario:** 2.515.099
- **Mediana del salario:** 1.050.000
- **Desviación estándar del salario:** 4.032.159

Se observa que la **media** del salario (2.515.099) es considerablemente superior a la **mediana** (1.050.000), lo cual sugiere que la distribución de los salarios está **sesgada positivamente**, es decir, existen jugadores con salarios muy elevados que elevan el promedio.

Además, la **desviación estándar** (4.032.159) es muy alta en relación con la media, lo que indica una gran **variabilidad** en los salarios. Esto refuerza la idea de que hay una diferencia significativa entre los jugadores que menos y más ganan, reflejando una estructura salarial desigual dentro del conjunto analizado.




Figura 3.3: Salario medio según la posición del jugador




Figura 3.4: Salario medio según si el jugador ha sido internacional

De estos dos gráficos podemos sacar las siguientes conclusiones:

- El salario no se ve muy influenciado dependiendo la posición del jugador aunque sorprendentemente son los delanteros los que menos cobran por lo general y los defensas los que más (a priori daba por hecho que no iba a ser así)

- El hecho de que a un jugador lo llame su selección afecta de manera directa al salario.




Figura 3.5: Boxplots de los salarios diferenciados por equipo

Estos gráficos vienen a reafirmar el hecho de la diferencia salarial entre unos equipos y otros. Se pueden observar las enormes diferencias entre las distribuciones salariales de Real Madrid, Barça y Atlético de Madrid con el resto de clubes de LaLiga, siendo Lewandowski un outlier muy diferencial. Teniendo en cuenta solamente los diez jugadores mejor pagados de cada equipo, los tres equipos de arriba reúnen más de un 50 % de la masa salarial de LaLiga.

Estudio de las correlaciones de la variable Salario con todas las demás

Ahora procedemos a estudiar las correlaciones de todas las variables con la que posteriormente escogeremos como variable a predecir (Salario).

Se observa que las 5 variables de las que más depende el sueldo de un jugador son:

- `successful_passes_opposition_half` — Pases exitosos en campo contrario
- `assists_intentional` — Asistencias intencionadas

Distribución de la suma de salarios de los 10 mejores pagados por equipo




Figura 3.6: Diagrama de sectores de salarios por equipo teniendo en cuenta los 10 mejores pagados de cada club

successful_passes_opposition_half	0.41749371	assists_intentional	0.34397540	clean_sheets	0.32669142
open_play_passes	0.32513349	key_passes_attempt_assists	0.30501022	goals	0.28049405
shots_on_target_inc_goals	0.27317126	successful_long_passes	0.25240306	successful_passes_own_half	0.25075810
total_touches_in_opposition_box	0.23425620	date_of_birth	-0.22320090	forward_passes	0.20766724
hit_woodwork	0.17492022	time_played	0.15784362	total_fouls_won	0.14544232
successful_dribbles	0.12122878	appearances	0.11414589	games_played	0.11414589
duels_won	0.08346043	blocks	0.05849074	tackles_won	0.05845361
total_clearances	-0.02596899	aerial_duels_won	-0.01379173		

Figura 3.7: Correlaciones de salario

- clean_sheets — Partidos sin goles encajados
- open_play_passes — Pases en jugada abierta
- key_passes_attempt_assists — Pases clave / intentos de asistencia

La variable clean_sheets es una estadística que verdaderamente no depende del jugador, así que cuadra bastante que aparezca como la tercera, debido a que los tres de arriba son los que más porterías a cero dejan.




Figura 3.8: Top 5 correladas

3.1.3 Análisis predictivo de los salarios de la plantilla del Real Betis Balompié

Ya pasamos a la parte de predicción. Concretamente nos vamos a centrar en mi equipo, el Betis, y en sus jugadores. Vamos a tomar como conjunto entrenamiento a todos los jugadores de LaLiga menos a los del Betis, ya que estos van a ser nuestro conjunto test. Mi objetivo no es conseguir un modelo que tenga una buena precisión, sino encontrar jugadores que estén rindiendo por encima o por debajo de sus pretensiones económicas. Vamos a usar tanto XGBoost como RandomForest con la librería `tidymodels`.

1. Separamos los datos en conjunto entrenamiento y conjunto test

Observemos las funciones de densidad de ambos conjuntos.




Figura 3.9: Densidad salarios Betis vs resto de LaLiga

2. Construcción del modelo y entrenamiento de este

Primero con randomforest

```
# 1. Receta
receta <- recipe(Salario ~ ., data = training(split)) %>%
  step_mutate(position = as.factor(position)) %>%
  step_dummy(all_nominal(), one_hot = FALSE)

# 2. Modelo
modelo_rf <- rand_forest(
  trees = 100,
  mtry = floor(sqrt(ncol(datos_modelo) - 1)),
  min_n = 2
) %>%
  set_engine("ranger") %>%
  set_mode("regression")

# 3. Entrenamiento
```

```
wf <- workflow() %>%  
  add_recipe(receta) %>%  
  add_model(modelo_rf)  
  
modelo_rf_final <- last_fit(wf, split)  
  
# 4. Métricas  
metricas <- modelo_rf_final %>% collect_metrics()
```

Ahora con XGBoost

```
# 1. Receta mínima con conversión de variables lógicas  
receta <- recipe(Salario ~ ., data = training(split)) %>%  
  step_mutate(  
    position = as.factor(position),  
    international = as.integer(international)  
  ) %>%  
  step_dummy(all_nominal(), one_hot = FALSE)  
  
# 2. Modelo XGBoost rápido  
modelo_xgb <- boost_tree(  
  trees = 100,  
  tree_depth = 6,  
  min_n = 2,  
  learn_rate = 0.1  
) %>%  
  set_engine("xgboost") %>%  
  set_mode("regression")  
  
# 3. Workflow  
wf_xgb <- workflow() %>%  
  add_recipe(receta) %>%  
  add_model(modelo_xgb)  
  
# 4. Entrenamiento y ajuste final  
modelo_final_xgb <- last_fit(wf_xgb, split)
```

```
# 5. Métricas
```

```
metricas_xgb <- modelo_final_xgb %>% collect_metrics()
```

```
# 6. Métricas
```

```
metricas_xgb <- modelo_final_xgb %>% collect_metrics()
```

```
print(metricas_xgb)
```

3. Predicciones y análisis de los resultados




Figura 3.10: Salarios reales vs predichos RANDOM FOREST

Este modelo es más optimista con jugadores con salario bajo y no se queda lejos de jugadores con salario muy alto para lo que es el Betis (Isco). Como aficionado del Betis y hablando en nombre de todos los béticos, Isco rinde incluso por encima de lo que cobra, pero creo que el modelo no rinde del todo bien con jugadores con alto salario. También estoy de acuerdo con la mayoría del resto de predicciones: jugadores como A.Diao, Ruibal, Ayoze, Chadi o Johnny han rendido por encima de sus pretensiones económicas. De hecho A.Diao y Ayoze han salido del club y están haciendo temporadas magníficas. Concretamente, el caso de Ayoze fue muy sonado ya que el Villarreal vio en él una oportunidad de mercado al tener una cláusula baja y le ofreció un mejor contrato de lo que el Betis le podía ofrecer.




Figura 3.11: Histograma salarios reales vs predichos RANDOM FOREST




Figura 3.12: Salarios reales vs predichos RANDOM FOREST

En el caso de las predicciones del modelo XGBoost me choca mucho la predicción del salario de Isco. Habría que fijarse bien en cuál ha sido el motivo para que dé una




Figura 3.13: Histograma salarios reales vs predichos RANDOM FOREST

predicción tan baja al jugador que mejor ha rendido en toda la temporada.

4. Comparación del rendimiento de ambos modelos

.metric<chr>	.estimator<chr>	.estimate<dbl>	.config<chr>	Modelo<chr>
rmse	standard	1.115260e+06	Preprocessor1_Model1	Random Forest
rsq	standard	6.286007e-01	Preprocessor1_Model1	Random Forest
rmse	standard	1.162338e+06	Preprocessor1_Model1	XGBoost
rsq	standard	4.229004e-01	Preprocessor1_Model1	XGBoost

Figura 3.14: Comparación del RMSE y R² de ambos modelos

Como ya expliqué en la parte de teoría, las métricas utilizadas para comparar modelos son el RMSE y el R². De todas maneras, los modelos que he construido no buscan la precisión, ya que quiero determinar el salario que "verdaderamente" se merecen los jugadores en base a su rendimiento, luego no estoy buscando estimaciones precisas.

Aún así, si tuviese que sacar alguna conclusión: el modelo de Random Forest muestra mejor rendimiento que XGBoost en este análisis, con un 20 % más de varianza explicada y un error ligeramente menor. Por lo que en lo estudios que voy a realizar sobre este conjunto de datos voy a trabajar con el modelo RandomForest.

5. Otros estudios sobre el modelo y su rendimiento

Importancia de las variables en el modelo RandomForest




Figura 3.15: Importancia de las variables en el modelo RF

Las variables más importantes a la hora de entrenar al modelo RandomForest son: open_play_passes, clean_sheets, blocks y succesful_passes tanto en campo propio como en campo rival. También tiene mucha importancia que el jugador en cuestión pertenezca al Madrid y al Barça. Esto me hace pensar que debería haber quitado estas variables a la hora de entrenar el modelo, y puede ser uno de los motivos por los que la predicción del salario de Isco es distinta a la que pensaba.

Más gráficos de importancia

El jugador del que más se sobreestimó su salario fue Chadi Riad. Tiene sentido, debido a que Chadi venía de la cantera del Barça y fue una apuesta del director deportivo. Tenía un contrato muy bajo y finalmente acabó ganándose el puesto de titular. De hecho, ese mismo verano acabó fichando por un equipo de la liga inglesa siendo un negocio redondo para el Betis.

Otras maneras de construir el modelo

Es verdad que a lo mejor coger como el conjunto **train** a todos los jugadores de LaLiga no es acertado ya que el Betis no tiene la misma capacidad económica que los




Figura 3.16: Errores de predicción

tres equipos de la zona alta de la tabla. Debido a esto, vamos a estudiar cuáles son los equipos con una estructura salarial más parecida a la del Betis para construir un modelo solamente con estos equipos. Para ver los equipos que pagan a sus jugadores de manera más parecida al Betis vamos a usar la distancia K-S, y posteriormente graficaremos las funciones de densidad de los que obtengamos resultados más parecidos (ver Figura 3.18).

equipo <chr>	distancia_KS <dbl>	similitud_global <chr>
RSO	0.1503268	45.61%
GET	0.1638655	59.87%
ATH	0.1764706	35.72%
GIR	0.2217195	49.64%
VAL	0.2394958	34.96%
VIL	0.2549020	43.59%
CAD	0.3104575	20.66%
SEV	0.3250774	9.90%

Figura 3.17: Similitud calculada con la distancia K-S




Figura 3.18: Funciones de densidad de los equipos más parecidos al Betis

Sacamos en conclusión que los equipos más parecidos al Betis en cuanto a la forma de pagar a sus jugadores se refiere son: Real Sociedad, Getafe, Athletic, Girona, Valencia y Villarreal, así que vamos a construir un modelo en el que los jugadores de estos equipos sean el conjunto train para ver qué tipo de predicciones nos da.

Observamos que los resultados (ver Figura 3.19). son muy parecidos a los obtenidos anteriormente. Una curiosidad de este modelo es que en la importancia de las variables aparecía como una de las variables más importantes que se apellidase Williams. Esto se debe a que los hermanos Williams tienen un salario inusual en un equipo como el Athletic, ya que al tener la filosofía de solo fichar jugadores vascos pueden ofrecer mejores sueldos a sus jugadores.




Figura 3.19: Histograma de los resultados entrenados con el modelo de equipos similares

Análisis con PCA

PCA (Análisis de Componentes Principales) es una técnica estadística que permite **reducir la cantidad de variables** en un conjunto de datos, manteniendo la mayor parte de la **información relevante**. Es especialmente útil cuando existen muchas variables correlacionadas.

Funcionamiento

- Identifica patrones en los datos.
- Transforma las variables originales en un nuevo conjunto llamado componentes principales.
- Cada componente es una combinación lineal de las variables originales y están ordenados según cuánta **varianza** explican.

Ejemplo aplicado al fútbol

Queremos analizar el rendimiento de varios jugadores usando las siguientes variables:

- Pases completados por partido
- Recuperaciones por partido
- Disparos al arco por partido
- Porcentaje de posesión

Aplicamos PCA para reducir las 4 variables a 2 componentes principales:

- **Componente 1: Participación ofensiva**
- **Componente 2: Contribución defensiva**

Esto nos permite representar a los jugadores en un plano 2D y agruparlos según su perfil:

- Delanteros ofensivos: alto en Componente 1
- Mediocampistas defensivos: alto en Componente 2
- Jugadores equilibrados: intermedios en ambos

Ventajas

- Simplifica el análisis de múltiples variables.
- Facilita la visualización y agrupamiento de perfiles de jugadores.
- Ayuda en decisiones estratégicas como scouting o alineaciones.

Aplicación en Rstudio

```
#Componentes principales  
step_pca(all_predictors(), threshold = 0.7)
```

Componente <int>	Varianza_Acumulada <dbl>
1	0.3407621
2	0.5091622
3	0.5816930
4	0.6374714
5	0.6742264
6	0.7035240
7	0.7229933
8	0.7419021
9	0.7584548
10	0.7723445

Figura 3.20: Varianza acumulada




Figura 3.21: Varianza acumulada

El threshold = 0.7 indica que quieres conservar suficientes componentes principales como para explicar al menos el 70 % de la varianza total de las variables predictoras originales.

Se observa claramente cómo a partir de la sexta componente ya se explica el 70 % de la varianza, por tanto nos quedamos con 6 componentes.

Comparación Salarios Reales vs Predichos




Figura 3.22: Comparación usando PCA

Sorprende la predicción de Isco.

Otro modelo que podía haber probado: hacer distintos modelos para cada posición del campo: defensas, mediocentros y delanteros, ya que las estadísticas entre estos varían bastante así como sus estructuras salariales: el gol se paga mejor que las acciones defensivas.

3.2 Análisis y predicción de asistencia a un estadio de fútbol

Para esta parte del trabajo he utilizado un conjunto de datos elaborado por mí mismo, recopilando información de la web oficial de la Real Sociedad [9]. Este conjunto de datos contiene registros de asistencia al estadio Reale Arena a lo largo de varias temporadas, junto con variables relevantes como el rival, la fecha del partido, el día de la semana, la hora, la posición en la tabla, el resultado previo, o si se trataba de una jornada especial (por ejemplo partido europeo). He cogido los datos correspondientes a los partidos como local de las últimas tres temporadas ya que antes de

esta había restricciones en los estadios por el COVID.

El objetivo principal de este capítulo es realizar un análisis descriptivo y predictivo que permita comprender los factores que influyen en la asistencia al estadio y estimar el número de asistentes en función de diferentes características del encuentro. Este enfoque puede resultar especialmente valioso para la planificación de recursos logísticos, estrategias de marketing y optimización de ingresos por taquilla. Además, se pretende ofrecer una herramienta que contribuya a una gestión más eficiente y sostenible del club desde el punto de vista económico y organizativo.



Figura 3.23: Estadio de la Real Sociedad

Decidí hacerlo de la Real Sociedad ya que creo que no tiene mucho sentido hacerlo del Real Betis debido a que el estadio del Betis siempre o casi siempre tiene un público superior a los 50k asistentes, por lo que al haber poca variabilidad entre los datos no saldrían resultados muy concluyentes. Sin embargo, justo antes de empezar a hacer el trabajo de fin de grado, viendo un partido de la Real Sociedad vi las gradas vacías en gran parte cuando otros partidos las había visto muy llenas así que me decidí a hacer el estudio sobre este club. Ojo, no estoy diciendo que la afición de la Real Sociedad sea mala, simplemente que a lo mejor allí hay otra cultura sobre el fútbol, el tiempo es peor y San Sebastián tiene bastantes menos habitantes que Sevilla, entre otras razones.



Figura 3.24: Imagen que muestra el problema de asistencia en algunos partidos

3.2.1 Obtención y tratamiento de datos

Probablemente una de las partes mas tediosas de mi trabajo de fin de grado, ya que no hay ninguna página web que recoja los datos que requería para hacer este estudio. Fui buscando en la página web de la Real Sociedad las asistencias a los distintos partidos uno a uno junto a otras variables como la fecha o la hora del partido que tuve que buscar en páginas de datos futbolísticos como soccerway.

Ficha técnica:

Real Sociedad: Remiro, Traoré (Aramburu, min.65), Aritz, Zubeldia, Javi López (Mariezcurrrena, min.81), Zubimendi, Marín (Turrientes, min.65), Brais Méndez (Sučić, min.58), Barrene (Sergio Gómez, min.58), Take y Oyarzabal (cap).

Girona FC: Krapyytsov, Arnau, Francés, Krejci, Blind, Solís (Abel Ruiz, min.60), Herrera (Romeu, min.87), Iván Martín (Arthur Melo, min.61), Tsygankov (Danjuma, min.87), Asprilla y Stuari (cap)(Portu, min.69).

Goles: 1-0: Marín, min.5. 1-1: Stuari, min.10. 2-1: Oyarzabal, min.20. 2-2: Portu, min.77. 3-2: Mariezcurrrena, min.91.

Árbitro: Ortiz Arias. Ha amonestado al local Traoré y a los visitantes Solís, Stuari y Arnau.

Asistencia: 28.135 espectadores.

Figura 3.25: Ficha técnica del último partido en casa de la Real

La dimensión de mi base de datos es de 75x12, es decir, 12 variables de 75 partidos. Al haber hecho yo mismo la base de datos, no voy a tener problemas con valores NA, ya que no he dejado ningún valor vacío.

Estudio de las variables

Se van a exponer las distintas variables que hemos tenido en cuenta para realizar este estudio y el motivo del por qué me ha parecido interesante incluirlas en mi estudio.

- **Rival** : Rival contra el que se juega el partido.
- **Competición** : Competición que juega el equipo. La UEFA o la copa pueden afectar negativamente a los datos de asistencia mientras que la Champions siempre afecta de manera positiva
- **Mes** : Mes en el que se disputó el partido
- **Estación** : Estación del año en la que se disputó el partido. Tanto el mes como la estación son variables interesantes de estudiar ya que en los meses en los que hace mejor tiempo los estadios suelen estar más llenos.
- **Lluvia** : Si llovió o no ese día. Por mi experiencia personal la lluvia es un factor muy importante a la hora de que un aficionado acuda o no al estadio de su equipo. En este caso la Real cuenta con una ventaja y es que las gradas están completamente techadas por la estructura de su estadio
- **Racha** : Suma de puntos cosechados por el equipo en las tres jornadas anteriores. De esta manera es un valor que va del 0 al 9. Podremos comprobar si los aficionados de la Real se dejan influenciar por las rachas del equipo y pierden el interés en ir al campo cuando los resultados no acompañan
- **Importancia** : Es una mezcla entre la importancia del partido y la importancia del rival. del 1 al 3. Por ejemplo, todos los partidos contra el Athletic, el Barça o el Madrid los he calificado con un 3, debido a que despiertan mucho interés entre los aficionados. Sin embargo, hay rivales que dependiendo del momento de la temporada varían su valor en la variable importancia, ya que puede ser un partido clave para la Real para su calificación a competición europea por ejemplo.
- **Asistencia** : Número de asistentes.
- **Resultado** : Resultado del partido. Realmente esta variable no la vamos a incluir en nuestros estudios pero no me costaba mucho esfuerzo anotar los resultados.
- **Día** : Día en el que se jugó el partido. Hay mucha variabilidad de público entre un partido que se juega el sábado a uno que se juega el lunes por ejemplo.
- **Hora** : Hora a la que se disputó el partido. Para la afición no es lo mismo asistir al estadio un domingo a las tres de la tarde que a las nueve de la noche por ejemplo.

- **Semanas** : Número de semanas que han pasado desde que se jugó el último partido en casa. Me parece importante tenerlo en cuenta dado que partidos como el primero de liga u ocasiones en la que el equipo juega una gran cantidad de partidos seguidos fuera de casa pienso que la afición recibe al equipo de una forma distinta

Pasamos a factor las variables Competición y Lluvia. Pasamos la hora al formato horas, minutos y segundos para que sea más fácil su interpretación y clasificación. La hora de los partidos la vamos a clasificar en pronto (12-15:30), pm (15:30-17:30), tarde (17:30-20:00) y noche (20:00 en adelante).

3.2.2 Análisis descriptivo del conjunto de datos

A continuación se presentan una serie de visualizaciones diseñadas para comprender en profundidad los factores que influyen en la **asistencia a los partidos de fútbol**. Este análisis exploratorio se centra en variables de contexto como la competición, el rival, el momento del año y otras circunstancias que pueden tener un impacto directo en el número de espectadores.

Este estudio incluye:

- El análisis de **correlaciones** entre la asistencia y diversas variables contextuales (como la importancia del partido, la estación del año o si llovió), con el objetivo de identificar cuáles de ellas tienen mayor capacidad explicativa sobre el volumen de público.
- La elaboración de **gráficos de barras, histogramas y boxplots** que muestran cómo varía la asistencia en función de categorías como el mes del año, el día de la semana, el rival o la competición en disputa.
- La exploración de **tendencias temporales**, como el comportamiento de la asistencia a lo largo de las semanas de la temporada o el momento del día en que se juega el encuentro.
- La evaluación del impacto de variables como la **racha deportiva del equipo** o la **importancia relativa del partido**, que pueden influir en la decisión del público de acudir o no al estadio.
- Visualizaciones que permiten contrastar **diferencias estacionales y meteorológicas**, como el efecto de la lluvia o de jugar en ciertas estaciones del año sobre la asistencia.

Estas representaciones gráficas aportan una visión clara y estructurada del comportamiento de los asistentes en los eventos deportivos, y constituyen una base sólida para futuras decisiones estratégicas del club o de la organización, ya sea en términos de planificación, marketing, horarios o logística.

Se incluyen ejemplos que ilustran cómo un director de operaciones o marketing puede apoyarse en este análisis estadístico y visual para detectar patrones de asistencia, identificar partidos de riesgo en cuanto a baja afluencia o diseñar campañas orientadas a mejorar el número de espectadores según variables contextuales clave.

Este estudio le podría venir bien incluso a la policía de San Sebastián para planificar dispositivos policiales dependiendo del público que se estime que acuda al partido.

Gráficos en los que se observa el comportamiento de la asistencia en relación a distintas variables

Importancia del partido




Figura 3.26: Boxplot según importancia

Podemos ver que, claramente, la importancia influye directamente en la asistencia del partido, como era de esperar. Rivalen como el Madrid, el Barça y el Athletic (derbi) hacen que los aficionados vayan al estadio sin pensárselo. La asistencia más alta se




Figura 3.27: Media de asistencia según nivel de importancia




Figura 3.28: Asistencia vs Importancia del partido

registró contra el PSG en champions puesto que era un partido histórico al no haber alcanzado nunca esa ronda de la competición.

Competición




Figura 3.29: Medias de asistencia por competición

Se observa que la competición que más valoran los aficionados es la Champions y la que menos la Uefa. Esto se debe a que en la Uefa hay muchos partidos de rondas iniciales que son contra rivales poco conocidos y al ser entre semana no despierta mucha pasión entre los txuri-urdines (apodo por el que también se conoce a los aficionados de la Real Sociedad).

Sería interesante que el club sacase promociones de entradas para estos partidos para así hacer más caja.

Momento del partido

No se observa gran diferencia entre los distintos momentos de los partidos, aunque se puede apreciar una tendencia al alza cuanto más tarde sea la hora del encuentro.




Figura 3.30: Media de asistencia por momento del partido




Figura 3.31: Asistencia vs Racha

Racha

No se aprecia mucha diferencia en la asistencia dependiendo de la racha que lleve el equipo antes del partido en cuestión. Aún así, también se puede observar un incre-

mento de la asistencia si el equipo lleva una buena racha. De todas maneras, no se puede afirmar que los aficionados de la Real dejen a su equipo de lado cuando este pasa una mala racha

Mes




Figura 3.32: Evolución de la asistencia por mes

En los meses en los que hace mejor tiempo se registran mejores datos de asistencia aunque esto no es para nada concluyente considerando que en todos los meses no se ha jugado la misma cantidad de partidos ni contra los mismos rivales. El mes que presenta una afluencia mayor en el estadio es noviembre, aunque habría que ver cuantos partidos se han jugado en cada mes.

Lluvia




Figura 3.33: Distribución según la lluvia

Estudio de las correlaciones

variable <chr>	correlation <dbl>	abs_correlation <dbl>
Rival	0.71616580	0.71616580
Importancia	0.70573837	0.70573837
Día	0.19028056	0.19028056
Mes	0.16849778	0.16849778
Semanas	0.11268758	0.11268758
Competición	0.09459733	0.09459733
Estación	0.08218554	0.08218554
Racha	-0.03324529	0.03324529
Momento	0.02995956	0.02995956
Lluvia	0.01626445	0.01626445

Figura 3.34: Correlaciones

Se observa que la variable que más correlación tiene es la importancia del partido de la mano del rival (ya que vienen a significar prácticamente lo mismo).




Figura 3.35: Gráfico correlaciones

3.2.3 Análisis predictivo de la asistencia al estadio de la Real Sociedad

1. Separamos los datos en conjunto entrenamiento y conjunto test

Al haber poca cantidad de datos, lo que más interesa es que el modelo se entrene lo más correctamente posible, así que vamos a hacer que el conjunto de entrenamiento sea un 85 % de la base de datos. Vamos a estratificar los datos por la variable importancia. Estratificar significa dividir los datos manteniendo la proporción de una variable (en este caso, Importancia) tanto en el conjunto de entrenamiento como en el de prueba.

¿Por qué hacerlo? Si no estratificas, puede que una clase (por ejemplo, partidos de importancia 3) quede desbalanceada entre entrenamiento y prueba, lo que da lugar a un modelo que no aprende bien o que se evalúa injustamente.

Como muestra la gráfica 3.36, la elección del conjunto train y del conjunto test ha sido muy buena ya que las funciones de densidad de parecen bastante.




Figura 3.36: Gráfico de funciones de densidad del conjunto train y test

2. Construcción del modelo y entrenamiento de este

Procederemos con randomforest puesto que es con el que he obtenido mejores resultados en el anterior caso práctico.

```
# Receta
rf_recipe <- recipe(Asistencia ~ Rival + Mes + Competición + Estación +
  Lluvia + Racha + Importancia + Día + Semanas + Momento,
  data = train_data) %>%
  step_novel(all_nominal_predictors()) %>%
  step_dummy(all_nominal_predictors()) %>%
  step_zv(all_predictors()) %>%
  step_normalize(all_numeric_predictors())

# Especificación del modelo con tuning y permutación
rf_model <- rand_forest(
```



```
mtry = tune(),
trees = 100,
min_n = tune()
) %>%
  set_engine("ranger", importance = "permutation") %>%
  set_mode("regression")

# Flujo de trabajo
rf_wf <- workflow() %>%
  add_model(rf_model) %>%
  add_recipe(rf_recipe)

# Validación cruzada
cv_folds <- vfold_cv(train_data, v = 5, strata = Importancia)

# Rango de hiperparámetros
rf_grid <- grid_regular(
  mtry(range = c(2, 5)),
  min_n(range = c(2, 10)),
  levels = 3
)

# Tuning
rf_tuned <- tune_grid(
  rf_wf,
  resamples = cv_folds,
  grid = rf_grid,
  metrics = metric_set(rmse, rsq)
)

# Seleccionar el mejor modelo
best_rf <- select_best(rf_tuned, metric = "rmse")
```

Este es el código utilizado para elaborar el modelo. En este caso he utilizado `tune` para encontrar la mejor combinación de parámetros. Ejecuta varios modelos y se queda con el que mejor RMSE tenga. También como he explicado antes, he añadido a la hora de hacer la recata `strata = importancia`.

.metric <chr>	.estimator <chr>	.estimate <dbl>
rmse	standard	3121.6348350
rsq	standard	0.5537571
mae	standard	2847.5548612

Figura 3.37: RMSE y R^2

3. Predicciones




Figura 3.38: Asistencia real vs predicha

No son los resultados soñados, pero para tener tan pocos datos no considero que sean unas predicciones muy erróneas.




Figura 3.39: Asistencia real vs predicha

4. Análisis de los resultados

.metric<chr>	.estimator<chr>	.estimate<dbl>
rmse	standard	3121.6348350
rsq	standard	0.5537571
mae	standard	2847.5548612

Figura 3.40: RMSE y R² del modelo

MSE y MAE razonables: si los valores de asistencia suelen estar en un rango de, por ejemplo, 10.000–60.000, un error de unos 3.000 es aceptable pero no perfecto.

RMSE vs MAE: Como el RMSE > MAE, eso indica que hay algunos errores grandes (el RMSE penaliza más los errores grandes).

R² del 55 %: es un resultado moderadamente bueno. El modelo captura algo más de la mitad de la variabilidad en la asistencia, pero queda margen de mejora.

5. Importancia de las variables




Figura 3.41: Las 10 variables más importantes

Se observa que el factor más importante es que la importancia del partido sea un 3. Después vemos algunos factores menos esperados como el mes_09, que se refiere al mes de julio dado que en este mes solo se ha jugado un partido y hubo muchísima asistencia. Luego, obviamente, que los rivales sean Barça, Madrid y Athletic influye bastante. También, que el partido sea el martes ya que este día es cuando se disputa la Champions y la entrada más numerosa se registró este día.

Otros modelos

No he quedado muy satisfecho con los resultados y voy a probar a eliminar la variable Rival del modelo. Pienso que por diversas circunstancias en un partido contra un rival pudo haber mucha asistencia por un motivo extraordinario, entonces el modelo no estaría siendo bien entrenado.

.metric <chr>	.estimator <chr>	.estimate <dbl>
rmse	standard	2899.309665
rsq	standard	0.568544

Figura 3.42: RMSE y R^2 del modelo del modelo sin tener en cuenta la variable rival




Figura 3.43: Asistencia real vs predicha del modelo sin tener en cuenta rival

Como sospechaba este modelo funciona mejor. Las predicciones han mejorado y tanto el RMSE como el R^2 han mejorado. Saco la conclusión de que la variable rival sesgaba los resultados.




Figura 3.44: Importancia de las variables en el modelo sin Rival

Para mejorar la elaboración de este modelo se me ocurre ser más específico y distinguir entre la importancia del partido y la importancia del rival ya que a equipos como el Atlético de Madrid le he dado la misma importancia que el Athletic y eso no debería ser así.

3.2.4 Construcción de una app Shiny a través de Rstudio

Shiny es un paquete de R que permite construir aplicaciones web interactivas de forma sencilla y rápida, sin necesidad de conocimientos avanzados en programación web. A través de Shiny, es posible crear interfaces gráficas que facilitan la visualización, manipulación y análisis de datos, haciendo accesibles resultados y modelos estadísticos a usuarios finales.

En el caso de mi TFG he decidido hacer una app Shiny para predecir la asistencia de todos los partidos que se nos ocurran.

Predicción de Asistencia - Random Forest

Mes:

Mayo

Competición:

LIGA

Estación:

Primavera

¿Llovió?

No

Racha (1 a 9):

7

Importancia (1 = Baja, 3 = Alta):

2

Día de la semana:

Sábado

Semanas desde último partido:

1

Momento del día:

pronto

Predicir asistencia

Resultado de la Predicción

Asistencia estimada: 29688

El valor predicho se basa en un modelo de Random Forest entrenado con datos históricos del equipo usando tidymodels.

Figura 3.45: App Shiny

4 | Conclusiones

Me ha encantado realizar este trabajo de fin de grado porque ha conseguido reunir mis dos pasiones: el fútbol y la estadística. Siento que he aprendido mucho a lo largo del proceso de su realización, pues me ha permitido adentrarme tanto en el mundo de la inteligencia artificial como en las aplicaciones de esta ciencia en el fútbol.

Mi sueño es trabajar algún día en el departamento de análisis de datos de algún club de fútbol y si fuera en el Real Betis Balompié sería ideal. Al final, el sueño de toda persona es dedicarse a algo que le apasione y que no le suponga esfuerzo dedicarle horas y horas. Para mí, dedicarme al mundo del fútbol sería vivir de la que es mi afición y ojalá en un futuro no muy lejano lo pueda conseguir.

Muchos aficionados a este deporte siguen estando muy alejados del mundo de los datos y lo entiendo, ya que lo que reina en el deporte en general es el corazón y el sentimiento, pero considero que una cosa no anula a la otra. El dato está para complementar, no para sustituir. Ocurre como en el arte, se podrán inventar todas las inteligencias artificiales que se quiera, que el sentimiento que plasma un artista en un cuadro no lo logrará hacer una inteligencia sin sentimientos. Un ojeador de futbolistas que lleve toda su vida viendo jugadores va a tener mucha más intuición que yo para saber si un futbolista va a acabar triunfando o no, pero yo le puedo dar herramientas a este ojeador para que capte aspectos que a lo mejor el simple ojo no puede apreciar tan fácilmente.

Pienso que la estadística todavía está muy alejada de la mayoría de seguidores del balompié pero tengo esperanzas en que poco a poco esta situación cambiará, ya que aunque a priori parezca un mundo muy complejo, hay métricas que son muy fáciles de entender y pueden ser la explicación de muchos aspectos del juego. Una simple media, mediana o varianza pueden hacernos entender por qué un jugador no rinde de la manera en la que debería o por qué un equipo juega mejor que otro.

Por este motivo, en verano me adentraré en un proyecto de divulgación: crearé una cuenta de Instagram para hacer llegar la estadística a los futboleros que todavía no la tengan en cuenta como un factor importante. La cuenta se llamará HNStats, H por Heliópolis y N por Nervión: los dos barrios que acogen a los dos grandes equipos de esta ciudad.



Figura 4.1: Logo de la cuenta de Instagram



Figura 4.2: Ejemplo de publicación que subiré

Son imágenes muy simples con datos curiosos sobre jugadores que el mero espectador no valora y pueden llamar bastante la atención. Por ejemplo, Ayoze provocó 32 córners (el que más del Betis). En principio este dato puede parecer irrelevante pero esto indica que el jugador canario siempre está rondando el área y provocando ocasiones de peligro.



Figura 4.3: Ejemplo de publicación que subiré

Hay futbolistas que muchas veces están en la sombra y no abren titulares ya que no marcan goles o no dan asistencias, pero el fútbol va mucho más allá de eso. Como dice Guardiola : "Hay jugadores que hacen que el equipo juegue bien y eso no se ve a simple vista. Hablan de los goles, las asistencias y se olvidan de todo lo demás. Eso es un problema del mundo real."

Un argumento en contra de las estadísticas del que estoy a favor es que la magia no se puede perder. Últimamente de las canteras están saliendo muchos futbolistas que juegan como robots, ya que parece que a lo largo de toda su etapa de formación los han entrenado para que sean efectivos, pero no estoy de acuerdo con esta práctica. El fútbol de la calle, los regates, la picaresca es algo que no se puede perder y que aporta mucho espectáculo a este deporte. Jugadores como Lamine Yamal nos hacen

acordarnos de los regateadores del pasado y al final, Lamine aprendió a jugar en la calle con sus amigos y no hay nada más bonito que eso. Cada vez que voy andando por la calle y veo a chavales jugando al fútbol, me alegro y pienso que el deporte está en buenas manos. Pero se puede tener cariño al pasado sin negar que tanto la sociedad como el fútbol están evolucionando y lo que tenemos que intentar los “científicos” es que avancen juntos de la mano el mundo de a pie y la ciencia.

En definitiva, el fútbol es mucho más que once personas detrás de un balón y eso lo demuestra la pasión que levanta en los aficionados y en la ciencia que puede haber detrás de él.

Bibliografía

- [1] CAPOLOGY. Salarios y Contratos La Liga 2023-2024, 2024. Disponible online.
- [2] DATACAMP. DataCamp en español: Aprende ciencia de datos e inteligencia artificial en línea, s.f. Disponible online.
- [3] LA MEDIA INGLESA. EL BRENTFORD ES EL NUEVO MATAGIGANTES: ASÍ DESESPERA A LOS GRANDES. Video disponible en YouTube.
- [4] LUQUE CALVO, P. L. *Guión: uso de la plantilla para hacer un TFG*, 2024.
- [5] LUQUE CALVO, PEDRO L. Página personal de Pedro L. Luque, 2021.
- [6] MUÑOZ-PICHARDO, J. M., AND PINO MEJÍAS, R. Apuntes de estadística computacional 2, 2024.
- [7] NATIONAL GEOGRAPHIC. El primer partido de fútbol oficial de la historia. Disponible en Historia National Geographic.
- [8] OFFSIDERS PODCAST. ¿Fútbol cada vez más predecible? ¿Se está perdiendo el talento? Así son los datos | SARA CARMONA, 2024. Entrevista a Sara Carmona disponible en YouTube.
- [9] REAL SOCIEDAD DE FÚTBOL S.A.D. Sitio web oficial de la Real Sociedad, s.f. Disponible online.
- [10] REEP, CHARLES. Skill and Chance in Association Football. *Journal of the Royal Statistical Society. Series A (General)* 131, 4 (1968), 581–585. Disponible online.
- [11] WEISS, ANDRÉS. Charles Reep, la modernidad del pasado, 2020. Disponible en La Media Inglesa.
- [12] WHISPERINGKAHUNA. LaLiga Performance Analysis | Guide, 2024. Notebook disponible en Kaggle.